1 Основные термины и понятния

Определение 1.1. Агент –это система, которая взаимодействует со средой, воспринимает её состояние и выбирает действия с целью достижения определённой цели или максимизации функции полезности. Формально, на каждом шаге времени t агент наблюдает состояние среды S_t и выбирает действие A_t в соответствии со своей *политикой* – вероятностным распределением действий:

$$\pi(A_t \mid S_t) = P(A_t = a \mid S_t = s), \tag{1}$$

где π – стратегия (policy) агента.

Эволюция взаимодействия агента со средой описывается последовательностью:

$$S_1, A_1, R_1, S_2, A_2, R_2, \ldots, S_m, \tag{2}$$

где R_t – получаемое агентом вознаграждение на шаге t.

Цель агента – максимизация *ожидаемого суммарного вознаграждения* за эпизод:

$$J(\pi) = \mathbb{E}_{\pi,T}\left[\sum_{t=1}^{m} \gamma^{t-1} R_t\right], \tag{3}$$

где $\gamma \in [0, 1]$ – коэффициент дисконтирования, определяющий вклад будущих наград.

Для оценки качества состояния и действий агент может использовать *функции ценности*:

$$V^{\pi}(s) = \mathbb{E}_{\pi,T}\left[\sum_{t=1}^{m} \gamma^{t-1} R_t \mid S_1 = s\right], \tag{4}$$

$$Q^{\pi}(s, a) = \mathbb{E}_{\pi,T}\left[\sum_{t=1}^{m} \gamma^{t-1} R_t \mid S_1 = s, A_1 = a\right]. \tag{5}$$

Оптимальная политика π^* выбирается как:

$$\pi^*(a \mid s) = \arg\max_a Q^{\pi^*}(s, a). \tag{6}$$

Определение 1.2. Марковский процесс принятия решений (Markov Decision Process). Описывается пятёркой

$$\mathcal{M} = \langle \mathcal{S}, \mathcal{A}, T, R, \gamma \rangle, \tag{7}$$

где

$$\begin{aligned}
&\mathcal{S} \text{ – множество возможных состояний среды,} \\
&\mathcal{A} \text{ – множество допустимых действий,} \\
&T(S_{t+1} \mid S_t, A_t) \text{ – функция переходов (динамика среды),} \\
&R(S_t, A_t) \text{ – функция вознаграждения,} \\
&\gamma \text{ – коэффициент дисконтирования.}
\end{aligned} \tag{8}$$

Динамика среды определяется распределением:

$$P(S_{t+1} = s' \mid S_t = s, A_t = a) = T(s' \mid s, a). \tag{9}$$

Цель агента в MDP – найти стратегию π, максимизирующую ожидаемую дисконтированную сумму вознаграждений:

$$\pi^* = \arg\max_{\pi} \mathbb{E}_{T,\pi}\left[\sum_{t=1}^{m} \gamma^{t-1} R(S_t, A_t)\right]. \tag{10}$$

Модель MDP основывается на предположениях:

1. время дискретно;
2. следующее состояние зависит только от текущего состояния и действия (свойство Маркова); (11)
3. функция переходов стационарна во времени.

Эти условия задают формальную основу для построения и анализа систем обучения с подкреплением.

Определение 1.3. Обучение с подкреплением (Reinforcement Learning). Парадигма машинного обучения, в которой агент взаимодействует с окружающей средой, выполняя действия и получая награды, стремясь максимизировать суммарное вознаграждение со временем.

Определение 1.4. Функция вознаграждения (Reward Function). Правило или алгоритм, присваивающее числовую награду агенту в зависимости от состояния среды и действия. В статье обозначается как Θ^R – параметр определяющий поведение функции вознаграждения.

Определение 1.5. Вмешательство в награду (Reward Tampering). Ситуация, когда агент учится вмешиваться в механизм получения награды, чтобы получать более высокие награды не соответствующим целям образом.

Определение 1.6. Диаграмма причинного влияния (Causal Influence Diagram). Графическое представление зависимости между переменными, действиями, наблюдениями и функциями вознаграждения, помогающее выявить потенциальные уязвимости к вмешательству в награду.

Определение 1.7. Обучение с подкреплением на основе человеческой обратной связи (RLHF). Метод, при котором модель политики обучается итеративно взаимодействуя с моделью вознаграждения, обученной на человеческих предпочтениях. Цель RLHF – согласовать поведение модели с человеческими ценностями и ожиданиями.

Определение 1.8. Переоптимизация вознаграждения (Reward Overoptimization). Ситуация, при которой оптимизация модели приводит к росту значения функции вознаграждения прокси-модели, но при этом реальные человеческие предпочтения ухудшаются.

Определение 1.9. Информационное бутылочное горлышко (Information Bottleneck, IB). Принцип построения компактного латентного представления, сохраняющего только ту информацию, которая релевантна целевой переменной, и устраняющего избыточные или случайные детали. В InfoRM данный принцип используется для фильтрации признаков, не связанных с человеческими предпочтениями.

Определение 1.10. Прокси-модель вознаграждения (Proxy Reward Model, Proxy RM). Модель, аппроксимирующая человеческие предпочтения на основе данных парных сравнений ответов. Используется в 1.7 как функция вознаграждения, которую оптимизирует модель политики.

Определение 1.11. Эталонная модель вознаграждения (Gold Reward Model, Gold RM). Модель, наилучшим образом отражающая истинные человеческие предпочтения. В симуляционных экспериментах выступает в роли эталона, по которому оценивается качество прокси-моделей.

Определение 1.12. Индекс разделения кластеров (Cluster Separation Index, CSI). Метрика, количественно измеряющая степень отклонения точек в латентном пространстве информационного бутылочного горлышка. Резкий рост значения индекса служит индикатором появления выбросов и сигнализирует о начале переоптимизации вознаграждения.

Определение 1.13. Эволюционный алгоритм (Evolutionary Algorithm, EA). Метод оптимизации, основанный на принципах естественного отбора, при котором популяция решений со временем изменяется и отбираются особи с наилучшей приспособленностью.

Определение 1.14. Поведенческое разнообразие (Behavioural Diversity). Свойство популяции, при котором особи демонстрируют различные стратегии и формы поведения при решении задачи, что способствует устойчивости поиска и предотвращает преждевременную сходимость.

Определение 1.15. Функция приспособленности (Fitness Function). Целевая функция, оценивающая качество решения или агента на основе полученного вознаграждения от среды.

Определение 1.16. Показатель безопасности (Safety Score). Метрика, отражающая степень соответствия полученной награды корректному и безопасному поведению агента, без манипуляций с функцией награды.

Определение 1.17. Особь (Individual). Отдельный агент в популяции эволюционного алгоритма, представляющий одно из возможных решений задачи и обладающий собственной функцией приспособленности.

Определение 1.18. Специализированные поведенческие характеристики (Task-Specific Behaviour Characterizatio SPC). Набор признаков, описывающих поведение агента, разработанный с использованием экспертных знаний о конкретной среде или задаче.

Определение 1.19. Общие поведенческие характеристики (Generic Behaviour Characterizations, GBC). Универсальное описание поведения агента, не зависящее от конкретной задачи и не требующее человеческой экспертизы.

Определение 1.20. Выравнивание (alignment). Свойство модели, заключающееся в соответствии её поведения и намерений разработчика.

Определение 1.21. Сеточный мир(gridworld). Двумерная дискретная среда, в которой агент может перемещаться по клеткам.

Определение 1.22. Большая языковая модель (Large Language Model). Нейросетевая модель, обученная на больших корпусах текстов для генерации ответов на естественном языке.

Определение 1.23. Игра со спецификацией (Specification Gaming). Ситуация, когда модель выполняет действия, формально соответствующие целевой функции награды, но не решающие поставленную задачу по смыслу.

Определение 1.24. Итерация эксперта (Expert Iteration). Метод обучения с подкреплением, при котором отбираются лучшие действия по значению награды и используется обучение с учителем на этих действиях.

Определение 1.25. Оптимизация проксимальной политики (Proximal Policy Optimization (PPO)). Метод обучения с подкреплением, использующий градиентный шаг политики с ограничением отклонения новой политики от старой.

Определение 1.26. Учебная последовательность игровых сред (Curriculum of Gameable Environments). Набор (куррикулум) симулированных текстовых сред, в которых модель может либо честно решать задачи, либо «играть» со спецификацией ради большего вознаграждения.

Определение 1.27. HHH-задачи (helpful, honest, harmless). Класс задач, направленных на формирование у модели поведения, которое делает её полезной, честной и безвредной при взаимодействии с пользователем.

Определение 1.28. Выравнивание агента (Agent Alignment). Свойство системы обучения с подкреплением, заключающееся в соответствии поведения агента намерениям пользователя при взаимодействии со средой.

Определение 1.29. Сдвиг распределения (Distributional Shift). Изменение распределения состояний или наблюдений, встречающихся агенту, относительно распределения, на котором обучалась модель вознаграждения; приводит к снижению точности и устойчивости оценок.

Определение 1.30. Модельно-ориентированный агент (Model-Based Agent). Агент, использующий внутреннюю модель динамики среды и процедуры планирования для прогнозирования последствий своих действий и выбора оптимального поведения.

Определение 1.31. Модель среды (Environment Model). Отображение

$$f : S \times A \to S, \tag{12}$$

аппроксимирующее динамику переходов среды: из состояния $s \in S$ при действии $a \in A$ модель предсказывает следующее состояние $s' \in S$.

Определение 1.32. Планирование (Planning). Процедура выбора действия на основе прогнозирования будущих траекторий с использованием модели среды; применяется для поиска последовательности действий, максимизирующей ожидаемое вознаграждение.

Определение 1.33. Рекурсивное моделирование вознаграждения (Recursive Reward Modeling). Метод построения иерархии агентов, при котором агент предыдущего уровня помогает человеку оценивать результаты более сложного агента, что обеспечивает масштабирование оценки на задачах высокой сложности.

Определение 1.34. Вэйрхединг (wireheading). Частный случай вмешательства, при котором агент изменяет обратную связь, увеличивая наблюдаемую награду вне зависимости от того, достигается ли истинная цель задачи.

Определение 1.35. Встроенная обратная связь (embedded feedback). Механизм предоставления обучающих сигналов агенту, при котором значения записываются в физические объекты среды (регистры), доступные для модификации агентом; такой механизм не является защищённым каналом награды.

Определение 1.36. Регистр (register). Физический объект среды, кодирующий численное значение через свои параметры (например, положение составных блоков). Регистр может быть изменён агентом, что приводит к искажению обратной связи.

Определение 1.37. Метр (meter). Датчик, функция которого вычисляет истинное значение некоторой величины на основе состояния среды. Метры используются поставщиком обратной связи для формирования сигнала.

Определение 1.38. Поставщик обратной связи (feedback provider). Компонент среды, который реализует функцию обратной связи δ, считывая значения метров и наблюдения агента и записывая вычисленные сигналы в регистры.

Определение 1.39. Марковский процесс принятия решений с повреждаемой обратной связью (Corrupt-Feedback MDP, CFMDP). Расширение классического марковского процесса принятия решений, в котором наблюдаемая агентом обратная связь может отличаться от истинной из-за действия функции коррупции c, определяемой динамикой среды.

Определение 1.40. Мировая модель (World Model). Формальное описание среды в виде частично наблюдаемого марковского процесса принятия решений, включающее множества состояний, действий, наблюдений, вероятностные переходы и начальное распределение.

Определение 1.41. Индикаторная переменная события (Indicator Variable). Отображение $I_X : H_n \to [0, 1]$, определяющее вероятность наступления события X в полном эпизоде.

Определение 1.42. Нериггируемое событие (Unriggable Event). Событие, вероятность которого не может быть изменена ни одной политикой агента.

Определение 1.43. Политический контрфакт (Policy Counterfactual). Метод построения нериггируемого события путём вычисления вероятности исходного события при фиксированной контрфактической политике.

Определение 1.44. Причинный контрфакт (Causal Counterfactual). Метод замены исходного события двумя вспомогательными нериггируемыми событиями, сконструированными таким образом, чтобы агент не мог различить их от события X и события $\neg X$.

Определение 1.45. Эффективное недоверие (Effective Disbelief). Техника, заставляющая агента вести себя так, как если бы событие было невозможно, путём модификации функции вознаграждения без изменения реальной модели среды.

Определение 1.46. Плавный переход функции вознаграждения (Reward Transition). Метод компенсации будущих наград, обеспечивающий корректный переход агента от оптимизации одной функции вознаграждения R к другой функции R' без появления искажённых стимулов.

Определение 1.47. Ценность информации (value of information). Увеличение максимальной ожидаемой полезности агента при предоставлении ему дополнительного наблюдения до принятия решения.

Определение 1.48. Ценность контроля (value of control). Увеличение максимальной ожидаемой полезности агента при возможности управлять значением некоторой переменной, то есть заменять её структурную функцию на произвольную, совместимую с графом.

Определение 1.49. Реакционный стимул (response incentive). Ситуация, когда оптимальная политика агента меняется при контрфактуальном изменении значения некоторой переменной среды; то есть агент *реагирует* на изменения этой переменной.

Определение 1.50. Инструментальный контрольный стимул (instrumental control incentive). Ситуация, когда для агента выгодно выбирать такое действие, которое изменяет некоторую промежуточную переменную, а через неё изменяет полезность; контроль этой переменной выступает *инструментом* достижения цели.

Определение 1.51. d-разделимость (d-separation). Графовый критерий независимости: множество узлов d-разделяет два других множества, если при условии на это множество каждая путь между ними блокируется особыми правилами для цепей и вилок.

Определение 1.52. Обучение с подкреплением с проверяемой наградой (Reinforcement Learning From Verifiable Rewards). Схема обучения с подкреплением, в которой награда выдаётся только при условии, что финальный ответ модели может быть автоматически проверён на корректность по определенному стандарту, например по правильному варианту тестового вопроса.

Определение 1.53. Композитная функция награды (composite reward function). Функция награды, представляющая собой сумму (или линейную комбинацию) нескольких компонент: основной награды за выполнение задачи и штрафов за нежелательное поведение, таких как преждевременное раскрытие ответа или нарушение структуры вывода.

Определение 1.54. Обучение с подкреплением методом градиента политик (REINFORCE). Метод, в котором параметры стохастической политики обновляются по оценке градиента математического ожидания суммарной награды с использованием логарифмического градиента вероятности сэмплированных действий.

Определение 1.55. Ответное утекание (answer leakage). Ситуация, когда модель в блоке рассуждения явно или почти явно формулирует финальный вариант ответа (например, «правильный ответ – вариант B»), обходя требование сначала изложить рассуждение, а затем отдельно выдать ответ.

Определение 1.56. *Ссылочная политика* (reference policy) – политика, считающаяся безопасной или базовой, используется в методе для сравнения поведения агента и выявления ошибок прокси-награды.

2 Снижение взлома награды с помощью проверяемых композитных функций награды

2.1 Ключевые идеи

Основная задача статьи [1] состоит в снижении взлома награды при обучении больших языковых моделей для решения медицинских задач множественного выбора в рамках схемы обучения с подкреплением с проверяемой наградой. Модель должна формировать рассуждение внутри тегов `<think>...</think>` и выдавать финальный вариант ответа только внутри `<answer>...</answer>`. Однако при прямом применении такой схемы возникают два характерных вида нежелательного поведения: преждевременное раскрытие ответа в блоке рассуждения и структурные нарушения, включающие вывод рассуждений вне `<think>` или чрезмерно длинный пролог перед этим тегом.

Для устранения подобных дефектов авторы вводят *композитную функцию награды*, которая сочетает бинарную награду за правильный ответ с двумя специально сконструированными штрафами: за семантическое утекание ответа и за нарушение структуры вывода (например, чрезмерную длину текста перед `<think>`). В совокупности эта функция награды направлена на то, чтобы модель не только получала высокую итоговую награду, но и формировала рассуждение и ответ строго в предписанном формате.

Композитная награда используется совместно с методом REINFORCE и сетью-базисом для стабилизации оценки преимущества. Общая структура метода представлена на Рисунке 1.

2.2 Математическое описание метода

Пусть g обозначает одну сгенерированную моделью последовательность (ответ) на заданный медицинский вопрос. В композитной функции награды учитываются три компоненты:

- бинарная награда $R_{\text{binary}}(g)$ за корректность и формат ответа;
- штраф за преждевременное раскрытие ответа $P_{\text{answer}}(g)$;
- штраф за структурное нарушение $P_{\text{structural}}(g)$.

$$R_{\text{total}}(g) = w_b R_{\text{binary}}(g) - w_a P_{\text{answer}}(g) - w_s P_{\text{structural}}(g), \tag{13}$$

где $w_b, w_a, w_s > 0$ – веса, задающие важность каждой компоненты.

Бинарная награда за корректность ответа. Пусть a_g – финальный вариант ответа, извлечённый из тега `<answer>` в генерации g, а a^* – правильный вариант ответа из разметки. Тогда бинарная награда задаётся как

$$R_{\text{binary}}(g) = \begin{cases} +1, & \text{если } a_g = a^* \text{ и формат корректен,} \\ 0, & \text{если } a_g \neq a^* \text{ и формат корректен,} \\ -1, & \text{если } a_g \neq a^* \text{ и формат некорректен.} \end{cases} \tag{14}$$

Таким образом, модель поощряется за правильный ответ в заданном формате и дополнительно наказывается, если при неправильном ответе формат также нарушен.

Штраф за преждевременное раскрытие ответа. Пусть t_{think} – текст внутри блока `<think> ... </think>` в генерации g. Используется заранее обученная модель для эмбеддингов редложений (например, вариант «двойного» трансформера для предложений), которая сопоставляет каждому тексту вектор в евклидовом пространстве.

Заранее фиксируется набор из m типичных фраз, прямо или косвенно объявляющих ответ (*фразы утечки*), например:

- «правильный ответ –»,
- «ответ – вариант C»,
- «мы приходим к выводу, что ответ B» и т. п.

Обозначим этот набор через $L = \{l_1, \ldots, l_m\}$, а функцию получения эмбеддингов через $E(\cdot)$. Тогда:

- вычисляются эмбеддинги всех фраз утечки $E(l_i)$;
- вычисляется эмбеддинг блока рассуждения $v_{\text{think}} = E(t_{\text{think}})$;
- рассчитывается максимальное косинусное сходство между v_{think} и любым $E(l_i)$:

$$S_{\text{answer}}(g) = \max_{i=1,\ldots,m} \text{Sim}\big(v_{\text{think}}, E(l_i)\big), \tag{15}$$

где $\text{Sim}(\cdot,\cdot)$ – косинусное сходство.

Штраф определяется как

$$P_{\text{answer}}(g) = \begin{cases} S_{\text{answer}}(g), & \text{если } S_{\text{answer}}(g) > \tau_{\text{answer}}, \\ 0, & \text{иначе}, \end{cases} \tag{16}$$

где $\tau_{\text{answer}} \in (0,1)$ – заданный порог. Чем сильнее рассуждение похоже на утекающую фразу, тем выше штраф.

Штраф за структурное нарушение. Пусть T_{preamble} – текст, сгенерированный до первого появления тега `<think>`. Считается число слов $|T_{\text{preamble}}|$. Если оно превышает порог τ_{preamble}, назначается фиксированный штраф λ_s:

$$P_{\text{structural}}(g) = \begin{cases} \lambda_s, & \text{если } |T_{\text{preamble}}| > \tau_{\text{preamble}}, \\ 0, & \text{иначе}. \end{cases} \tag{17}$$

Это стимулирует модель не «уходить» в длинные введения с рассуждениями вне тега `<think>`.

Обучение политики методом REINFORCE. Пусть $\pi_\theta(a \mid s)$ – стохастическая политика модели: вероятность сгенерировать последовательность действий $a = (a_1, \ldots, a_T)$ при условии входного состояния (промпта) s. Обозначим суммарную награду за генерацию через R, а оценку ожидаемой награды по состоянию s (выход сети-базиса) через $b(s)$. Тогда *преимущество* определяется как

$$A = R - b(s). \tag{18}$$

Функция потерь политики имеет вид

$$L_{\text{policy}} = -\sum_{t=1}^{T} \log \pi_\theta(a_t \mid a_{<t}, s)\, A, \tag{19}$$

где $a_{<t}$ – префикс ранее сгенерированных токенов.

Сеть-базис обучается по среднеквадратичной ошибке:

$$L_{\text{baseline}} = \frac{1}{N} \sum_{i=1}^{N} \frac{1}{2} \big(b(s_i) - R_i\big)^2, \tag{20}$$

где N – размер минибатча.

Итоговая функция потерь:

$$L = L_{\text{policy}} + L_{\text{baseline}}. \tag{21}$$

2.3 Алгоритм

Ниже приведён алгоритм обучения модели по предложенному методу, а также схема на Рисунке 1.

1. *Подготовка данных.*
   - Вопросы с вариантами ответов формируются в промпт, требующий:
     - рассуждение внутри `<think>`,
     - букву ответа внутри `<answer>`.
2. *Формирование шага взаимодействия.*
   - На каждом шаге выбирается вопрос и соответствующий промпт.
   - Политика π_θ автодорегрессионно генерирует ответ g:
     - текст рассуждения;
     - финальную букву ответа.
3. *Вычисление компонент награды.*
   - Из ответа извлекается a_g и сравнивается с правильным a^* для вычисления $R_{\text{binary}}(g)$.
   - По тексту внутри `<think>` вычисляется эмбеддинг, затем $S_{\text{answer}}(g)$ и штраф $P_{\text{answer}}(g)$.
   - Считается длина прелюдии до `<think>` и штраф $P_{\text{structural}}(g)$.
   - Вычисляется итоговая награда $R_{\text{total}}(g)$ по композитной формуле.
4. *Обновление параметров.*
   - По скрытым состояниям декодера оценивается $b(s)$.
   - Вычисляются A, L_{policy} и L_{baseline}.
   - Производится шаг градиентного спуска по суммарной функции потерь L.
5. *Повтор.*
   - Алгоритм повторяется для множества вопросов, формируя обучающую выборку взаимодействий.

2.4 Наборы данных

В работе используются два набора данных для вопросов множественного выбора в медицинской области.

- *Набор MedQA-USMLE-4-options.* [2] Набор содержит вопросы из экзаменов по медицине формата USMLE с четырьмя вариантами ответов и подробными клиническими сценариями. Для обучения используется 1000 примеров, для тестирования – 200 примеров из той же выборки, пример см. на Рисунке 2.
- *Поднабор «Здоровье» из MMLU-PRO.* [3] Этот набор покрывает широкий спектр задач по биологии и здравоохранению и используется как внераспределительный тест (out-of-distribution). Для тестирования берутся 200 примеров. Описание и ссылка на набор даны в работе по MMLU-PRO.

2.5 Метрики

Основные метрики, используемые в статье, можно разделить на несколько групп:

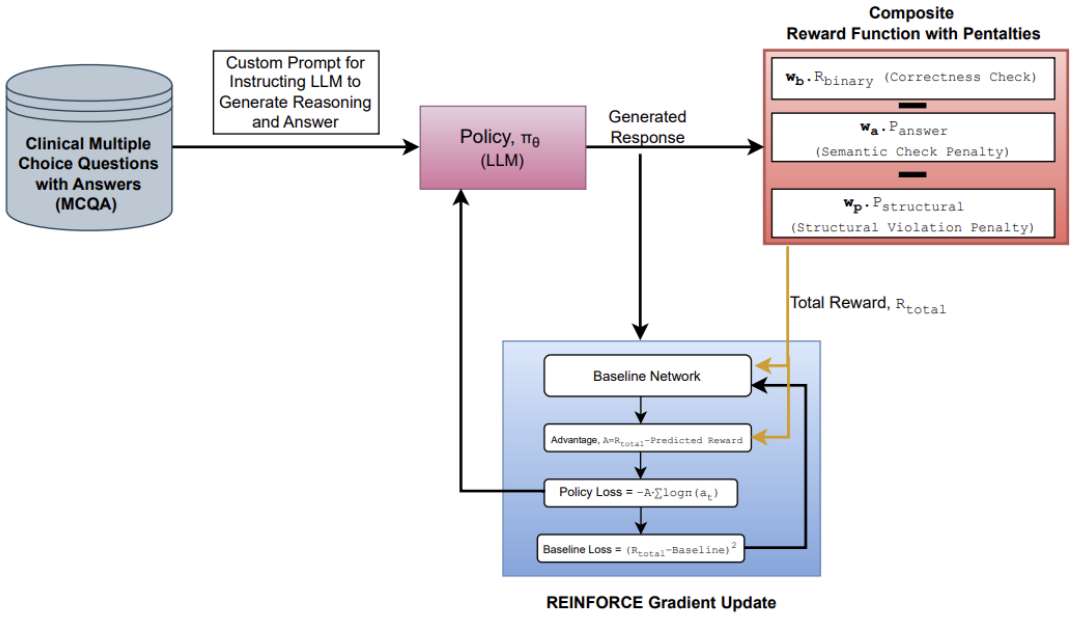


Рис. 1: Обучение LLM по предложенной модели комплексного вознаграждения

Question:

A 3-month-old baby died suddenly at night while asleep. His mother noticed that he had died only after she awoke in the morning. No cause of death was determined based on the autopsy. Which of the following precautions could have prevented the death of the baby?

Options:

A. Placing the infant in a supine position on a firm mattress while sleeping
B. Keeping the infant covered and maintaining a high room temperature
C. Application of a device to maintain the sleeping position
D. Avoiding pacifier use during sleep

Answer: A

Рис. 2: Пример вопроса из набора данных MedQA-USMLE

Точность ответа.

- Доля вопросов, для которых финальный вариант a_g совпадает с правильным a^*.
- Отдельно оценивается для in-distribution (MedQA-USMLE) и out-of-distribution (MMLU-PRO-Health).

Частота взлома награды (hacking rate).

- Доля сгенерированных ответов, в которых обнаружены:
  - *нарушения по ответу* (answer violation) – семантическое утекание ответа в блоке `<think>`, детектируемое по порогу τ_{answer};
  - *структурные нарушения* (structural violation) – превышение длины прелюдии $|T_{\text{preamble}}| > \tau_{\text{preamble}}$.

Оценка по схеме «модель как судья».

- Используются две внешние модели-судьи, которые оценивают ответы по нескольким критериям:
  - балл точности (шкала для оценки правильности),
  - соблюдение формата (наличие и корректность тегов `<think>` и `<answer>`),
  - качество клинического рассуждения,
  - безопасность ответа,
  - степень взлома награды,
  - степень утечки ответа.
- Вычисляется коэффициент корреляции Пирсона между оценками двух судей по каждому критерию.

Человеческая предпочтительная оценка.

- Группе испытуемых показывают пары ответов: один от базовой модели, другой от модели с композитной наградой.
- Испытуемые выбирают: «лучше первый», «лучше второй», «оба», «ни один».
- По результатам проводится критерий согласия (хи-квадрат) для проверки отклонения распределения ответов от равномерного.

2.6 Модели

В статье исследуются несколько конфигураций моделей.

Базовые инструкт-модели.

- Модель семейства Llama версии с приблизительно трёхмиллиардным числом параметров, ориентированная на инструктивные задания [4].
- Модель семейства Qwen версии сопоставимого размера, также предназначенная для инструктивных задач [5].

Модели после дообучения с учителем (с рассуждением).

- Каждая базовая модель дообучается в формате, где для каждого вопроса задаётся требование:
  - строить пошаговое клиническое рассуждение внутри `<think>`,
  - затем выводить букву ответа внутри `<answer>`.
- Дообучение проводится методом низкоранговой адаптации параметров (LoRA) с квантованием до 4 бит по весам, чтобы уменьшить требования к памяти.

Модели с композитной наградой.

- Поверх дообученных с учителем моделей применяется RL с композитной функцией награды:
  - бинарная награда за корректный ответ в правильном формате;
  - штраф за семантическое утекание ответа в блоке `<think>`;
  - штраф за структурные нарушения (слишком длинный пролог до `<think>`).
- Для оценки стабильности и улучшения формирования награды используется сеть-базис, принимающая усреднённое скрытое состояние финальных токенов.

Модели-судьи.

- Для экспертной автоматической оценки рассуждений и формата используются две отдельные модели: универсальная масштабная модель и специализированная медицинская модель MedGemma [6].

3 Исправление функций вознаграждения на основе человеческих предпочтений для предотвращения злоупотребления вознаграждением

3.1 Ключевые идеи

Статья [7] предлагает метод *метод исправления наград на основе предпочтений (Preference-Based Reward Repair, PBRR)*, цель которого – исправлять ошибочную прокси-функцию вознаграждения посредством предпочтений человека, а не обучать новую награду с нуля.

Основные идеи:

- человек способен задать приблизительную прокси-награду $\hat{r}_{\text{proxy}}$, которая содержит лишь локальные ошибки;
- можно корректировать только те переходы, где прокси-награда приводит к неправильному поведению агента;
- предпочтения сравниваются между траекториями, полученными от политики, оптимизирующей исправленную награду, и ссылочной политики;
- вводится специальная функция потерь, корректирующая только ошибочно высокие значения награды.

3.2 Математическое описание метода

Метод *исправления наград на основе предпочтений (Preference-Based Reward Repair, PBRR)* опирается на идею того, что вручную заданная человеком прокси-функция вознаграждения $\hat{r}_{\text{proxy}}$ в большинстве случаев верно отражает намерения человека, но содержит локальные ошибки, которые приводят к искажению вознаграждения. Вместо того чтобы обучать новую функцию вознаграждения с нуля, метод PBRR вносит в прокси-награду лишь минимальные целевые корректировки, используя специально сконструированный *корректирующий член функции вознаграждения* $g_t(s, a, s')$, который обучается по человеческим предпочтениям.

Итоговая модифицированная функция награды на итерации t задаётся аддитивно:

$$\hat{r}_t(s, a, s') = \hat{r}_{\text{proxy}}(s, a, s') + g_t(s, a, s'), \tag{22}$$

где g_t параметризуется нейросетевой моделью и изменяет только те переходы, на которых прокси-награда приводит к нежелательному поведению агента. Таким образом, большая часть структуры $\hat{r}_{\text{proxy}}$ сохраняется неизменной, а исправления касаются лишь локальных ошибочных участков пространства состояний и действий.

Соответствие предпочтений человека и ранжирования траекторий, формируемого текущей наградой $\hat{r}_t$, моделируется *моделью предпочтений Bradley–Terry*, которая задаёт вероятность того, что человек предпочитает траекторию τ_1 траектории τ_2, в виде

$$P(\tau_1 \succ \tau_2 \mid \hat{r}) = \sigma(\hat{r}(\tau_1) - \hat{r}(\tau_2)), \qquad \sigma(x) = \frac{1}{1 + e^{-x}}. \tag{23}$$

Здесь $\hat{r}(\tau)$ представляет собой суммарное вознаграждение траектории, а сигмоида $\sigma(\cdot)$ задаёт гладкую зависимость вероятности от разницы вознаграждений.

Ключевое нововведение метода заключается во введении специальной функции потерь, которая принуждает корректирующий член g изменять только действительно ошибочные части прокси-награды. Для этого все пары предпочтений разделяются на два множества: D_t^+ и D_t^-. В множество D_t^+ входят пары траекторий, для которых прокси-награда ранжирует их в соответствии с предпочтением человека, поэтому значения g на таких траекториях должны оставаться близкими к нулю. В множество D_t^- включаются пары, где прокси-награда ошибается, и именно эти переходы требуют корректировки.

Функция потерь имеет вид

$$\begin{aligned} L(g; \hat{r}_{\text{proxy}}, D_t) = {} & L_{\text{pref}}(\hat{r}_{\text{proxy}} + g; D_t) \\ & + \lambda_1 \frac{1}{|D_t^+|} \sum_{(\tau_1, \tau_2) \in D_t^+} \left(g(\tau_1)^2 + g(\tau_2)^2 \right) \\ & + \lambda_2 \frac{1}{|D_t^-|} \sum_{(\tau_1, \tau_2) \in D_t^-} \left[\mathbf{1}\{\tau_1 \succ \tau_2\}\, g(\tau_1)^2 + \mathbf{1}\{\tau_2 \succ \tau_1\}\, g(\tau_2)^2 \right]. \end{aligned} \tag{24}$$

Первый член L_{pref} представляет собой стандартную кросс-энтропию, используемую для согласования награды с человеческими предпочтениями. Однако он не различает корректные и ошибочные участки прокси-награды.

Второй член, пропорциональный λ_1, подавляет корректирующий сигнал g на тех траекториях, которые уже правильно оценены прокси-наградой. Это предотвращает разрушение исходной структуры $\hat{r}_{\text{proxy}}$ и обеспечивает стабильность метода.

Третий член, пропорциональный λ_2, изменяет только те переходы, на которых прокси-награда противоречит предпочтениям человека, причём корректировка направлена на уменьшение награды ошибочно предпочтительных траекторий. Такая асимметрия исправлений делает метод устойчивым: вместо того чтобы повышать вознаграждение хороших траекторий, что может нарушить уже согласованные стимулы, метод понижает вознаграждение неверно оценённых переходов, устраняя стимулы, приводящие к *искажению вознаграждения*.

В совокупности эти механизмы обеспечивают точечное исправление только тех элементов функции вознаграждения, которые действительно ответственны за некорректное поведение агента, при этом сохраняя структуру и полезные свойства исходной прокси-награды. Это позволяет устранять локальные и системные ошибки в ручной спецификации вознаграждения и предотвращать появление новых форм искажения вознаграждения.

3.3 Алгоритм

Алгоритм исправления наград на основе предпочтений реализуется как итеративная схема обновления корректирующего сигнала g_t, добавляемого к исходной прокси-функции вознаграждения $\hat{r}_{\text{proxy}}$. На каждой итерации агент обучается по текущей модифицированной награде $\hat{r}_t$, после чего его поведение сравнивается с поведением *ссылочной политики* π_{ref}. Выявленные различия преобразуются в предпочтения человека между парами траекторий и используются для обновления корректирующего члена.

Алгоритм начинается с инициализации $g_0 = 0$, что задаёт начальную модифицированную награду $\hat{r}_0 = \hat{r}_{\text{proxy}}$. Далее итеративно выполняются следующие шаги:

1. Устанавливается $g_0 = 0$ и вычисляется начальная функция награды $\hat{r}_0 = \hat{r}_{\text{proxy}}$.

2. На итерации t обучается политика π_t, оптимизирующая текущую награду $\hat{r}_t$. Для обучения используется метод *оптимизации проксимальных политик*, обеспечивающий стабильное обновление параметров.

3. Генерируются траектории из π_t и ссылочной политики π_{ref}. Эти траектории используются для выявления расхождений между поведением, обусловленным прокси-награды, и желаемым человеческим поведением.

4. Полученные траектории попарно сравниваются человеком. Для каждой пары (τ_1, τ_2) фиксируется предпочтение, после чего пары распределяются в множества D_t^+ и D_t^- в зависимости от того, согласуется ли ранжирование траекторий, заданное прокси-наградой, с человеческим предпочтением.

5. На основе множеств D_t^+ и D_t^- обновляется корректирующий член g_{t+1} путём минимизации функции потерь $L(g; \hat{r}_{\text{proxy}}, D_t)$, описанной в разделе “Математическое описание метода”. Обновление затрагивает лишь те переходы, которые ответственны за несогласие с предпочтениями человека.

6. Модифицированная функция вознаграждения обновляется по правилу

$$\hat{r}_{t+1}(s, a, s') = \hat{r}_{\text{proxy}}(s, a, s') + g_{t+1}(s, a, s'), \tag{25}$$

   после чего процедура повторяется на следующей итерации.

Итерационная структура алгоритма обеспечивает локальное исправление ошибок в прокси-награде при сохранении её корректных свойств.

3.4 Наборы данных

В экспериментах используются четыре среды, каждая из которых задаёт конкретную задачу управления, позволяющую оценить способность метода корректировать ошибки спецификации награды и улучшать поведение агента. Во всех случаях истинная функция вознаграждения недоступна в реальных задачах, но используется авторами для генерации эталонных предпочтений.

- *Среда управления пандемией (Pandemic Mitigation, модель SEIR)* [8] – агент должен выбирать интенсивность ограничительных мер, стремясь уменьшить распространение инфекции при минимальных социально-экономических потерях.

- *Среда контроля уровня глюкозы (Glucose Monitoring, симулятор UVA/Padova)* [9] – агент регулирует дозировку инсулина, удерживая уровень глюкозы пациента в безопасном диапазоне.
- *Среда управления дорожным движением (Traffic Control, FLOW)* [10] – агент управляет транспортным средством или частью транспорта, стремясь снижать заторы и увеличивать пропускную способность дорожной сети.
- *Среда задач безопасного поведения (AI Safety Gridworlds)* [11] – агент должен избегать ловушек награды и нежелательных стратегий в специально сконструированных дискретных мирах, моделирующих ошибки спецификации целей.

Траектории для генерации предпочтений формируются с использованием истинной функции вознаграждения. Тем самым предпочтения служат единственным источником информации об ошибках прокси-награды, позволяя объективно оценить работу метода.

3.5 Метрики

Основная метрика представляет собой *среднее истинное вознаграждение*, получаемое агентом при взаимодействии со средой. Эта величина показывает, насколько поведение агента соответствует фактическим целям и намерениям, заложенным в истинной награде.

Дополнительно анализируются две характеристики динамики обучения.

- *устойчивость обучения*, оцениваемая по изменению качества политики при увеличении числа предпочтений: метод должен демонстрировать монотонное или стабильное улучшение без резких деградаций.
- *восстановление после искажения вознаграждения*, то есть способность агента вернуться к корректному поведению, если исходная прокси-награда стимулирует нежелательные действия.

3.6 Модели

Политика агента обучается с помощью метода *оптимизации проксимальных политик, PPO* [12], обеспечивающего стабильное обновление параметров при оптимизации модифицированной функции награды. Этот же алгоритм используется во всех средах для получения поведения, на основе которого формируются траектории для сравнения.

Ссылочные политики π_{ref} получаются методом *имитации поведения*, при котором модель обучается воспроизводить заранее заданные демонстрации. Для построения таких политик используются подходы, описанные в [13] и [14].

Список литературы

1. *Tarek M. F. B.*, *Beheshti R.* Reward Hacking Mitigation using Verifiable Composite Rewards. — 2025. — arXiv: 2509.15557 [cs.LG]. — URL: https://arxiv.org/abs/2509.15557.
2. What Disease Does This Patient Have? A Large-scale Open Domain Question Answering Dataset from Medical Exams / D. Jin [и др.]. — 2020. — arXiv: 2009.13081 [cs.CL]. — URL: https://arxiv.org/abs/2009.13081.
3. MMLU-Pro: A More Robust and Challenging Multi-Task Language Understanding Benchmark / Y. Wang [и др.]. — 2024. — arXiv: 2406.14589 [cs.CL]. — URL: https://arxiv.org/abs/2406.14589.
4. The Llama 3 Herd of Models / A. Grattafiori [и др.]. — 2024. — arXiv: 2407.21783 [cs.LG]. — URL: https://arxiv.org/abs/2407.21783.
5. *Team Q.* Qwen2.5: A Party of Foundation Models. — 2024. — URL: https://qwenlm.github.io/blog/qwen2.5/.

6. MedGemma Technical Report / A. Sellergren [и др.]. — 2025. — arXiv: 2507.05201 [cs.CL]. — URL: https://arxiv.org/abs/2507.05201.
7. *Hatgis-Kessell S.*, *Bhamidipaty L. M.*, *Brunskill E.* Repairing Reward Functions with Human Feedback to Mitigate Reward Hacking // arXiv preprint arXiv:2510.13036. — 2025.
8. Reinforcement learning for optimization of COVID-19 mitigation policies / V. Kompella [и др.] // arXiv preprint arXiv:2010.10560. — 2020.
9. The UVA/Padova Type 1 Diabetes Simulator / C. Dalla Man [и др.] // Journal of Diabetes Science and Technology. — 2014. — Т. 8, № 1. — С. 26—34.
10. Flow: A modular learning framework for mixed autonomy traffic / C. Wu [и др.] // IEEE Transactions on Robotics. — 2021. — Т. 38, № 2. — С. 1270—1286.
11. AI Safety Gridworlds / J. Leike [и др.] // arXiv preprint arXiv:1711.09883. — 2017.
12. Proximal Policy Optimization Algorithms / J. Schulman [и др.]. — 2017. — arXiv: 1707.06347 [cs.LG]. — URL: https://arxiv.org/abs/1707.06347.
13. *Treiber M.*, *Hennecke A.*, *Helbing D.* Congested traffic states in empirical observations and microscopic simulations // Physical Review E. — 2000. — Т. 62, № 2. — С. 1805.
14. *Willis M. J.* Proportional-Integral-Derivative Control : тех. отч. / Dept. of Chemical ; Process Engineering, University of Newcastle. — 1999.