1 Основные термины и понятния

Определение 1.1. Агент –это система, которая взаимодействует со средой, воспринимает её состояние и выбирает действия с целью достижения определённой цели или максимизации функции полезности. Формально, на каждом шаге времени t агент наблюдает состояние среды S_t и выбирает действие A_t в соответствии со своей *политикой* – вероятностным распределением действий:

$$\pi(A_t \mid S_t) = P(A_t = a \mid S_t = s), \tag{1}$$

где π – стратегия (policy) агента.

Эволюция взаимодействия агента со средой описывается последовательностью:

$$S_1, A_1, R_1, S_2, A_2, R_2, \ldots, S_m, \tag{2}$$

где R_t – получаемое агентом вознаграждение на шаге t.

Цель агента – максимизация *ожидаемого суммарного вознаграждения* за эпизод:

$$J(\pi) = \mathbb{E}_{\pi,T}\left[\sum_{t=1}^{m} \gamma^{t-1} R_t\right], \tag{3}$$

где $\gamma \in [0, 1]$ – коэффициент дисконтирования, определяющий вклад будущих наград.

Для оценки качества состояния и действий агент может использовать *функции ценности*:

$$V^{\pi}(s) = \mathbb{E}_{\pi,T}\left[\sum_{t=1}^{m} \gamma^{t-1} R_t \mid S_1 = s\right], \tag{4}$$

$$Q^{\pi}(s, a) = \mathbb{E}_{\pi,T}\left[\sum_{t=1}^{m} \gamma^{t-1} R_t \mid S_1 = s, A_1 = a\right]. \tag{5}$$

Оптимальная политика π^* выбирается как:

$$\pi^*(a \mid s) = \arg\max_a Q^{\pi^*}(s, a). \tag{6}$$

Определение 1.2. Марковский процесс принятия решений (Markov Decision Process). Описывается пятёркой

$$\mathcal{M} = \langle \mathcal{S}, \mathcal{A}, T, R, \gamma \rangle, \tag{7}$$

где

$$\begin{aligned}
&\mathcal{S} \text{ – множество возможных состояний среды,} \\
&\mathcal{A} \text{ – множество допустимых действий,} \\
&T(S_{t+1} \mid S_t, A_t) \text{ – функция переходов (динамика среды),} \\
&R(S_t, A_t) \text{ – функция вознаграждения,} \\
&\gamma \text{ – коэффициент дисконтирования.}
\end{aligned} \tag{8}$$

Динамика среды определяется распределением:

$$P(S_{t+1} = s' \mid S_t = s, A_t = a) = T(s' \mid s, a). \tag{9}$$

Цель агента в MDP – найти стратегию π, максимизирующую ожидаемую дисконтированную сумму вознаграждений:

$$\pi^* = \arg\max_{\pi} \mathbb{E}_{T,\pi}\left[\sum_{t=1}^{m} \gamma^{t-1} R(S_t, A_t)\right]. \tag{10}$$

Модель MDP основывается на предположениях:

1. время дискретно;
2. следующее состояние зависит только от текущего состояния и действия (свойство Маркова); (11)
3. функция переходов стационарна во времени.

Эти условия задают формальную основу для построения и анализа систем обучения с подкреплением.

Определение 1.3. Обучение с подкреплением (Reinforcement Learning). Парадигма машинного обучения, в которой агент взаимодействует с окружающей средой, выполняя действия и получая награды, стремясь максимизировать суммарное вознаграждение со временем.

Определение 1.4. Функция вознаграждения (Reward Function). Правило или алгоритм, присваивающее числовую награду агенту в зависимости от состояния среды и действия. В статье обозначается как Θ^R – параметр определяющий поведение функции вознаграждения.

Определение 1.5. Вмешательство в награду (Reward Tampering). Ситуация, когда агент учится вмешиваться в механизм получения награды, чтобы получать более высокие награды не соответствующим целям образом.

Определение 1.6. Диаграмма причинного влияния (Causal Influence Diagram). Графическое представление зависимости между переменными, действиями, наблюдениями и функциями вознаграждения, помогающее выявить потенциальные уязвимости к вмешательству в награду.

Определение 1.7. Обучение с подкреплением на основе человеческой обратной связи (RLHF). Метод, при котором модель политики обучается итеративно взаимодействуя с моделью вознаграждения, обученной на человеческих предпочтениях. Цель RLHF – согласовать поведение модели с человеческими ценностями и ожиданиями.

Определение 1.8. Переоптимизация вознаграждения (Reward Overoptimization). Ситуация, при которой оптимизация модели приводит к росту значения функции вознаграждения прокси-модели, но при этом реальные человеческие предпочтения ухудшаются.

Определение 1.9. Информационное бутылочное горлышко (Information Bottleneck, IB). Принцип построения компактного латентного представления, сохраняющего только ту информацию, которая релевантна целевой переменной, и устраняющего избыточные или случайные детали. В InfoRM данный принцип используется для фильтрации признаков, не связанных с человеческими предпочтениями.

Определение 1.10. Прокси-модель вознаграждения (Proxy Reward Model, Proxy RM). Модель, аппроксимирующая человеческие предпочтения на основе данных парных сравнений ответов. Используется в 1.7 как функция вознаграждения, которую оптимизирует модель политики.

Определение 1.11. Эталонная модель вознаграждения (Gold Reward Model, Gold RM). Модель, наилучшим образом отражающая истинные человеческие предпочтения. В симуляционных экспериментах выступает в роли эталона, по которому оценивается качество прокси-моделей.

Определение 1.12. Индекс разделения кластеров (Cluster Separation Index, CSI). Метрика, количественно измеряющая степень отклонения точек в латентном пространстве информационного бутылочного горлышка. Резкий рост значения индекса служит индикатором появления выбросов и сигнализирует о начале переоптимизации вознаграждения.

Определение 1.13. Эволюционный алгоритм (Evolutionary Algorithm, EA). Метод оптимизации, основанный на принципах естественного отбора, при котором популяция решений со временем изменяется и отбираются особи с наилучшей приспособленностью.

Определение 1.14. Поведенческое разнообразие (Behavioural Diversity). Свойство популяции, при котором особи демонстрируют различные стратегии и формы поведения при решении задачи, что способствует устойчивости поиска и предотвращает преждевременную сходимость.

Определение 1.15. Функция приспособленности (Fitness Function). Целевая функция, оценивающая качество решения или агента на основе полученного вознаграждения от среды.

Определение 1.16. Показатель безопасности (Safety Score). Метрика, отражающая степень соответствия полученной награды корректному и безопасному поведению агента, без манипуляций с функцией награды.

Определение 1.17. Особь (Individual). Отдельный агент в популяции эволюционного алгоритма, представляющий одно из возможных решений задачи и обладающий собственной функцией приспособленности.

Определение 1.18. Специализированные поведенческие характеристики (Task-Specific Behaviour Characterizatio SPC). Набор признаков, описывающих поведение агента, разработанный с использованием экспертных знаний о конкретной среде или задаче.

Определение 1.19. Общие поведенческие характеристики (Generic Behaviour Characterizations, GBC). Универсальное описание поведения агента, не зависящее от конкретной задачи и не требующее человеческой экспертизы.

Определение 1.20. Выравнивание (alignment). Свойство модели, заключающееся в соответствии её поведения и намерений разработчика.

Определение 1.21. Сеточный мир(gridworld). Двумерная дискретная среда, в которой агент может перемещаться по клеткам.

Определение 1.22. Большая языковая модель (Large Language Model). Нейросетевая модель, обученная на больших корпусах текстов для генерации ответов на естественном языке.

Определение 1.23. Игра со спецификацией (Specification Gaming). Ситуация, когда модель выполняет действия, формально соответствующие целевой функции награды, но не решающие поставленную задачу по смыслу.

Определение 1.24. Итерация эксперта (Expert Iteration). Метод обучения с подкреплением, при котором отбираются лучшие действия по значению награды и используется обучение с учителем на этих действиях.

Определение 1.25. Оптимизация проксимальной политики (Proximal Policy Optimization (PPO)). Метод обучения с подкреплением, использующий градиентный шаг политики с ограничением отклонения новой политики от старой.

Определение 1.26. Учебная последовательность игровых сред (Curriculum of Gameable Environments). Набор (куррикулум) симулированных текстовых сред, в которых модель может либо честно решать задачи, либо «играть» со спецификацией ради большего вознаграждения.

Определение 1.27. HHH-задачи (helpful, honest, harmless). Класс задач, направленных на формирование у модели поведения, которое делает её полезной, честной и безвредной при взаимодействии с пользователем.

Определение 1.28. Выравнивание агента (Agent Alignment). Свойство системы обучения с подкреплением, заключающееся в соответствии поведения агента намерениям пользователя при взаимодействии со средой.

Определение 1.29. Сдвиг распределения (Distributional Shift). Изменение распределения состояний или наблюдений, встречающихся агенту, относительно распределения, на котором обучалась модель вознаграждения; приводит к снижению точности и устойчивости оценок.

Определение 1.30. Модельно-ориентированный агент (Model-Based Agent). Агент, использующий внутреннюю модель динамики среды и процедуры планирования для прогнозирования последствий своих действий и выбора оптимального поведения.

Определение 1.31. Модель среды (Environment Model). Отображение

$$f : S \times A \to S, \tag{12}$$

аппроксимирующее динамику переходов среды: из состояния $s \in S$ при действии $a \in A$ модель предсказывает следующее состояние $s' \in S$.

Определение 1.32. Планирование (Planning). Процедура выбора действия на основе прогнозирования будущих траекторий с использованием модели среды; применяется для поиска последовательности действий, максимизирующей ожидаемое вознаграждение.

Определение 1.33. Рекурсивное моделирование вознаграждения (Recursive Reward Modeling). Метод построения иерархии агентов, при котором агент предыдущего уровня помогает человеку оценивать результаты более сложного агента, что обеспечивает масштабирование оценки на задачах высокой сложности.

Определение 1.34. Вэйрхединг (wireheading). Частный случай вмешательства, при котором агент изменяет обратную связь, увеличивая наблюдаемую награду вне зависимости от того, достигается ли истинная цель задачи.

Определение 1.35. Встроенная обратная связь (embedded feedback). Механизм предоставления обучающих сигналов агенту, при котором значения записываются в физические объекты среды (регистры), доступные для модификации агентом; такой механизм не является защищённым каналом награды.

Определение 1.36. Регистр (register). Физический объект среды, кодирующий численное значение через свои параметры (например, положение составных блоков). Регистр может быть изменён агентом, что приводит к искажению обратной связи.

Определение 1.37. Метр (meter). Датчик, функция которого вычисляет истинное значение некоторой величины на основе состояния среды. Метры используются поставщиком обратной связи для формирования сигнала.

Определение 1.38. Поставщик обратной связи (feedback provider). Компонент среды, который реализует функцию обратной связи δ, считывая значения метров и наблюдения агента и записывая вычисленные сигналы в регистры.

Определение 1.39. Марковский процесс принятия решений с повреждаемой обратной связью (Corrupt-Feedback MDP, CFMDP). Расширение классического марковского процесса принятия решений, в котором наблюдаемая агентом обратная связь может отличаться от истинной из-за действия функции коррупции c, определяемой динамикой среды.

Определение 1.40. Мировая модель (World Model). Формальное описание среды в виде частично наблюдаемого марковского процесса принятия решений, включающее множества состояний, действий, наблюдений, вероятностные переходы и начальное распределение.

Определение 1.41. Индикаторная переменная события (Indicator Variable). Отображение $I_X : H_n \to [0, 1]$, определяющее вероятность наступления события X в полном эпизоде.

Определение 1.42. Нериггируемое событие (Unriggable Event). Событие, вероятность которого не может быть изменена ни одной политикой агента.

Определение 1.43. Политический контрфакт (Policy Counterfactual). Метод построения нериггируемого события путём вычисления вероятности исходного события при фиксированной контрфактической политике.

Определение 1.44. Причинный контрфакт (Causal Counterfactual). Метод замены исходного события двумя вспомогательными нериггируемыми событиями, сконструированными таким образом, чтобы агент не мог различить их от события X и события $\neg X$.

Определение 1.45. Эффективное недоверие (Effective Disbelief). Техника, заставляющая агента вести себя так, как если бы событие было невозможно, путём модификации функции вознаграждения без изменения реальной модели среды.

Определение 1.46. Плавный переход функции вознаграждения (Reward Transition). Метод компенсации будущих наград, обеспечивающий корректный переход агента от оптимизации одной функции вознаграждения R к другой функции R' без появления искажённых стимулов.

Определение 1.47. Ценность информации (value of information). Увеличение максимальной ожидаемой полезности агента при предоставлении ему дополнительного наблюдения до принятия решения.

Определение 1.48. Ценность контроля (value of control). Увеличение максимальной ожидаемой полезности агента при возможности управлять значением некоторой переменной, то есть заменять её структурную функцию на произвольную, совместимую с графом.

Определение 1.49. Реакционный стимул (response incentive). Ситуация, когда оптимальная политика агента меняется при контрфактуальном изменении значения некоторой переменной среды; то есть агент *реагирует* на изменения этой переменной.

Определение 1.50. Инструментальный контрольный стимул (instrumental control incentive). Ситуация, когда для агента выгодно выбирать такое действие, которое изменяет некоторую промежуточную переменную, а через неё изменяет полезность; контроль этой переменной выступает *инструментом* достижения цели.

Определение 1.51. d-разделимость (d-separation). Графовый критерий независимости: множество узлов d-разделяет два других множества, если при условии на это множество каждая путь между ними блокируется особыми правилами для цепей и вилок.

Определение 1.52. Обучение с подкреплением с проверяемой наградой (Reinforcement Learning From Verifiable Rewards). Схема обучения с подкреплением, в которой награда выдаётся только при условии, что финальный ответ модели может быть автоматически проверён на корректность по определенному стандарту, например по правильному варианту тестового вопроса.

Определение 1.53. Композитная функция награды (composite reward function). Функция награды, представляющая собой сумму (или линейную комбинацию) нескольких компонент: основной награды за выполнение задачи и штрафов за нежелательное поведение, таких как преждевременное раскрытие ответа или нарушение структуры вывода.

Определение 1.54. Обучение с подкреплением методом градиента политик (REINFORCE). Метод, в котором параметры стохастической политики обновляются по оценке градиента математического ожидания суммарной награды с использованием логарифмического градиента вероятности сэмплированных действий.

Определение 1.55. Ответное утекание (answer leakage). Ситуация, когда модель в блоке рассуждения явно или почти явно формулирует финальный вариант ответа (например, «правильный ответ – вариант B»), обходя требование сначала изложить рассуждение, а затем отдельно выдать ответ.

2 Масштабируемое согласование агента посредством моделирования вознаграждения

2.1 Ключевые идеи

Статья [1] не предлагает конкретного алгоритма, а формулирует исследовательское направление, основанное на идее *моделирования вознаграждения* (reward modeling). Ключевая мысль состоит в том, что поведение обучаемого агента можно согласовывать с намерениями пользователя, если сначала обучать отдельную модель вознаграждения по человеческой обратной связи, а затем использовать её как целевую функцию для RL-агента.

Пользователь не задаёт награду вручную, а лишь оценивает результаты поведения агента (например, выбирает более удачные траектории). Модель вознаграждения учится воспроизводить такие оценки и служит прокси-функцией для обучения агента.

Дополнительно авторы предлагают идею *рекурсивного моделирования вознаграждения*: агент предыдущего уровня помогает пользователю оценивать результаты агента следующего уровня, упрощая процесс оценки в сложных задачах. В статье это представлено как концептуальная схема (рис. 1), а не как реализованный метод.

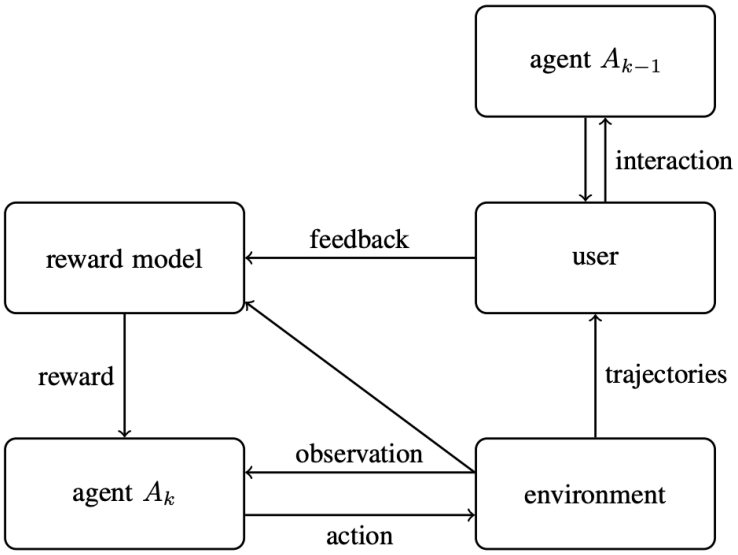


Рис. 1: Концептуальная схема рекурсивного моделирования вознаграждения. Агент A_{k-1} помогает пользователю оценить результаты агента A_k.

2.2 Описание метода

Авторы не вводят формальных определений, формул или точного алгоритма. Метод описывается лишь концептуально и включает следующие шаги:

- агент взаимодействует со средой и порождает траектории поведения;
- пользователь оценивает результаты (например, указывает предпочтения);
- модель вознаграждения обучается воспроизводить эти оценки;
- агент обновляет свою политику, ориентируясь на предсказания модели вознаграждения;
- цикл повторяется, постепенно улучшая и модель вознаграждения, и поведение агента.

Отдельно подчеркивается необходимость *онлайн-обучения*: модель вознаграждения должна обновляться параллельно с обучением агента, чтобы избежать ошибок из-за сдвига распределения.

2.3 Алгоритм

Алгоритм использует итеративную подстройку модели вознаграждения под меняющееся распределение состояний и корректирует ошибки, связанные со сдвигом распределения. Общая процедура моделирования вознаграждения может быть описана последовательностью:

1. Инициализировать модель вознаграждения R_θ и политику агента π.
2. Собрать набор траекторий $\{\tau_k\}$, сгенерированных текущей политикой.
3. Получить предпочтения пользователя над парами траекторий.
4. Обновить параметры модели вознаграждения путём минимизации функции потерь.
5. Обновить политику агента, максимизируя ожидаемое вознаграждение модели R_θ.
6. Повторять шаги 2-5, обеспечивая онлайн-обновление и адекватность оценок.

2.4 Наборы данных

В статье не используется конкретный набор данных, но сама процедура моделирования вознаграждения порождает собственный набор данных, состоящий из двух типов информации:

- Траектории поведения агента, собранные в процессе его взаимодействия со средой. Эти траектории включают наблюдения, действия и промежуточные результаты эпизодов.
- Человеческие предпочтения, полученные путём сравнения пар траекторий. Каждая аннотация задаёт бинарное предпочтение и служит обучающим сигналом для модели вознаграждения.

Подход к моделированию вознаграждения предполагает онлайн-сбор данных: по мере того как политика агента изменяется, изменяется и распределение траекторий. В связанных работах подобные схемы демонстрировались, например, на игровых средах Atari, которые используются как наглядный пример сложных задач с богатой динамикой.

2.5 Метрики

В статье не описывается формальные метрики, но обсуждаются желательные свойства:

- *Согласованность модели вознаграждения.* Оценивается совпадение между предсказаниями модели и реальными предпочтениями пользователя. В связанных работах это обычно выражается через корреляцию предсказанного и истинного вознаграждения на наборе удержанных траекторий или через точность восстановления предпочтений.
- *Производительность агента.* Измеряется итоговое суммарное вознаграждение, которое агент получает в среде, оптимизируя модель вознаграждения. Этот показатель отражает, насколько хорошо агент научился соответствовать предпочтениям пользователя, когда действует автономно.
- *Устойчивость к сдвигу распределения.* Проверяется способность модели корректно оценивать траектории, которые значительно отличаются от обучающих. Это характерно для случаев, когда политика агента улучшается и начинает посещать новые состояния.
- *Надёжность при планировании.* В задачах с моделью переходов дополнительно оценивается способность агента избегать нежелательных состояний и использовать предсказания модели среды для принятия более безопасных решений.

2.6 Модели

Структура метода включает несколько ключевых компонентов, которые взаимодействуют в процессе обучения (см. Рис 1).

- *Модель вознаграждения* R_θ. Представляет собой параметрическую функцию, обучаемую по предпочтениям пользователя. Она получает на вход траектории поведения, собранные в среде, и выдаёт скалярную оценку, которая должна согласовываться с человеческими предпочтениями.
- *Агент* A_k. Это обучаемая политика, которая взаимодействует со средой и использует предсказания модели вознаграждения для оптимизации поведения. Агент генерирует новые траектории, которые включаются в обучающий набор.
- *Вспомогательный агент* A_{k-1}. Используется в схеме рекурсивного моделирования вознаграждения. Он упрощает процесс оценки поведения агента A_k, помогая пользователю при сравнении сложных траекторий.
- *Модель переходов среды* (при наличии). Применяется в вариантах метода, где требуется планирование. Предоставляет приближённое предсказание будущих состояний по текущему состоянию и действию, что позволяет агенту оценивать потенциальные траектории без непосредственного запуска в среде.

В совокупности эти модели формируют цикл взаимодействия, в котором пользователь задаёт предпочтения, модель вознаграждения их интерпретирует, а агент адаптирует своё поведение, исходя из этих оценок.

3 REALab: встроенная перспектива на вмешательство

3.1 Ключевые идеи

Основная идея статьи [2] заключается в моделировании вмешательства в задачах обучения с подкреплением с помощью платформы REALab, которая обеспечивает *встроенную* обратную связь посредством физических регистров. В отличие от стандартных симуляторов, REALab не использует защищённый канал награды: вся обратная связь хранится в объектах среды, которые могут быть изменены агентом.

Платформа служит:

- инструментом для формального моделирования небезопасных механизмов обратной связи;
- тестовой средой для проверки устойчивости алгоритмов к вмешательству;
- операционализацией формализма CFMDP в реальной симуляции.

3.2 Математическое описание метода

Математическая структура задачи задаётся через марковский процесс принятия решений с искажённой обратной связью. Взаимодействие между агентом и средой происходит следующим образом:

$$\begin{aligned} A_t &\in A, \\ K_t &\in K, \\ D_{t+1} &= \delta(S_t, K_t), \\ \tilde{D}_{t+1} &= c(S_{t+1}, K_t, D_{t+1}), \\ S_{t+1} &\sim f(S_t, A_t), \end{aligned} \tag{13}$$

где δ – функция обратной связи, определяемая разработчиком агента, а функция c моделируется физикой симуляции.

Истинный возврат определяется как:

$$G = \sum_{t=0}^{T} \gamma^t r(S_t, A_t), \tag{14}$$

и не наблюдается агентом.

3.3 Алгоритм

REALab не задаёт фиксированный алгоритм обучения: вместо этого платформа определяет структуру взаимодействия между агентом и встроенными механизмами обратной связи. Алгоритм формируется разработчиком агента, который выбирает, каким образом использовать влияющие компоненты среды, и включает следующие шаги:

1. *Конфигурирование компонентов обратной связи.* Разработчик агента выбирает типы регистров, их расположение и необходимые метры. Эти компоненты определяют канал обратной связи, который физически присутствует в среде и подвержен вмешательству.

2. *Определение функции обратной связи δ.* Поставщик обратной связи получает наблюдения среды и (при необходимости) значения метров, после чего записывает вычисленное значение в выбранные регистры. Эта функция определяет, какие сигналы будут доступны агенту для обучения.

3. *Выбор алгоритма обучения.* Разработчик выбирает способ использования сигналов, поступающих через регистры: обучение по мгновенной награде, поведенческое клонирование, обучение по советам по ценности и т. д. Платформа не ограничивает выбор метода: она лишь предоставляет механизм доставки обучающих сигналов.

4. *Взаимодействие в ходе эпизода.* На каждом шаге агент получает наблюдение, формирует запрос K_t к поставщику обратной связи, выполняет действие A_t, после чего считывает значения из регистров. Записанное значение может отличаться от прочитанного вследствие физической динамики среды, что позволяет исследовать возникновение вмешательства.

Структура ролей проектировщика среды и проектировщика агента, а также их взаимодействие с симуляцией, показаны на Рисунке 2.

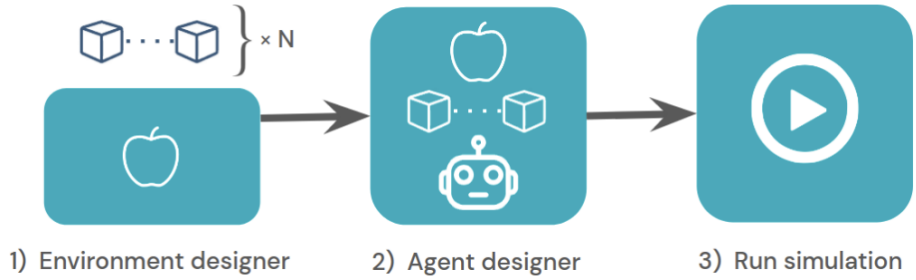


Рис. 2: Роли проектировщика среды и проектировщика агента в REALab. Проектировщик среды определяет задачу, динамику и доступные компоненты; проектировщик агента конструирует механизм обратной связи и алгоритм обучения; симулятор запускает обучение агента, который взаимодействует с компонентами среды и получает наблюдаемую, потенциально повреждённую обратную связь.

3.4 Наборы данных

В платформе REALab отсутствуют заранее подготовленные датасеты: обучение и оценка происходят непосредственно в трёхмерной симуляции. Такой формат позволяет изучать влияние действий агента на механизм обратной связи, поскольку все данные формируются динамически в процессе взаимодействия со средой. Источниками данных в REALab выступают:

- трёхмерные задачи на игровом движке Unity [3];
- задания, аналогичные средам DMLab-30 [4], например *сбор яблок* или *открытие двери*;
- компоненты среды (регистры, метры, поставщики обратной связи), которые создают обучающие сигналы во время взаимодействия агента с миром.

На Рисунке 3 приведён пример сцены в одной из задач: объект, предоставляющий награду, и *двухблочный регистр*, значение которого кодируется относительным положением блоков.

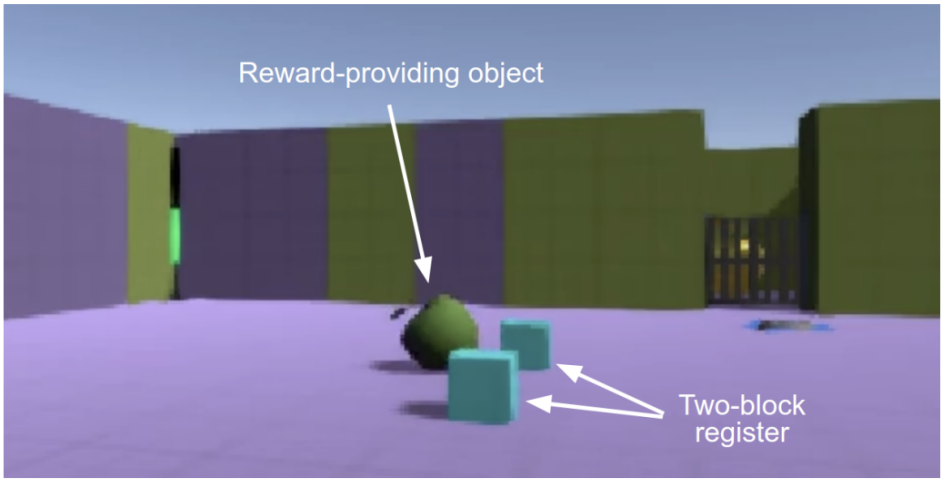


Рис. 3: Пример сцены в REALab: объект, обеспечивающий награду, и двухблочный регистр, хранящий значение обратной связи. Изменение положения блоков приводит к изменению закодированного значения, что моделирует вмешательство в механизм обратной связи.

3.5 Метрики

Для оценки поведения агента используются метрики, которые отражают два ключевых аспекта: соответствие поведения агента истинным задачам среды и наличие или отсутствие стимулов к вмешательству.

- *Истинный возврат* – основная метрика качества решения задачи. Она измеряет, насколько эффективно агент выполняет задание в соответствии с истинной функцией вознаграждения среды (которую он никогда напрямую не наблюдает). Истинный возврат определяется как сумма дисконтированных истинных наград:

$$G = \sum_{t=0}^{T} \gamma^t r(S_t, A_t). \tag{15}$$

  Высокое значение G означает, что поведение агента действительно полезно в заданном мире, а не только по наблюдаемой обратной связи.

- *Коррупция регистра* – метрика, отражающая степень вмешательства агента в каналы обратной связи. В REALab запись значения обратной связи происходит через физические регистры, которые агент может непреднамеренно или намеренно изменять. Коррупция измеряется как абсолютная разница между значением, записанным поставщиком обратной связи, и тем значением, которое затем считывает агент:

$$C = \left| D^{\text{write}} - D^{\text{read}} \right|, \tag{16}$$

где D^{write} – значение, которое поставщик обратной связи отправил в регистр, а D^{read} – значение, которое агент прочитал после физической эволюции среды.

Значение $C > 0$ указывает на то, что агент изменил регистр либо напрямую, либо косвенно.

- *Сравнение агентов по двумерному показателю* – метрика, позволяющая одновременно учитывать полезность поведения и уровень вмешательства. Для каждого агента вычисляется пара значений

$$(\text{истинный возврат},\ \text{уровень коррупции}), \tag{17}$$

что позволяет сравнивать различные архитектуры не только по успешности выполнения задания, но и по тому, насколько они склонны к вэйрхедингу или другим формам вмешательства.

3.6 Модели

REALab позволяет исследовать различные механизмы обучения, отличающиеся тем, как агент получает обратную связь через физические, подверженные вмешательству регистры. Ниже приведены три класса моделей, используемых в статье.

- *Агент с мгновенной наградой* [5]. Поставщик обратной связи считывает текущее изменение счёта через метр и записывает его в регистр. Агент воспринимает записанное значение как награду. Поскольку регистр является физическим объектом, изменение его положения или столкновения с ним приводят к искажению наблюдаемой награды.

- *Агент имитационного обучения* [6]. Поставщик обратной связи вычисляет действие демонстратора по текущему наблюдению и записывает его в регистр. Агент обучается повторять эти действия. Такая модель позволяет изучить, может ли агент стремиться менять регистр для упрощения демонстраций.

- *Агент, использующий советы по ценности* [7, 8]. Поставщик обратной связи вычисляет значение $Q(o, a)$ для наблюдения и выбранного действия, после чего записывает его в регистр. Агент стремится максимизировать наблюдаемое значение совета, что создаёт сильные стимулы к вмешательству в регистр, поскольку изменение его положения напрямую влияет на получаемую оценку.

Поведение агентов, использующих советы по ценности, иллюстрируется на Рисунке 4: когда агент оказывается рядом с регистром, он может переключиться с выполнения задачи на изменение положения регистра, повышая наблюдаемую полезность.

Каждая модель определяется выбором поставщика обратной связи:

- приращение счёта;
- действие демонстратора;
- значение $Q(o, a)$.

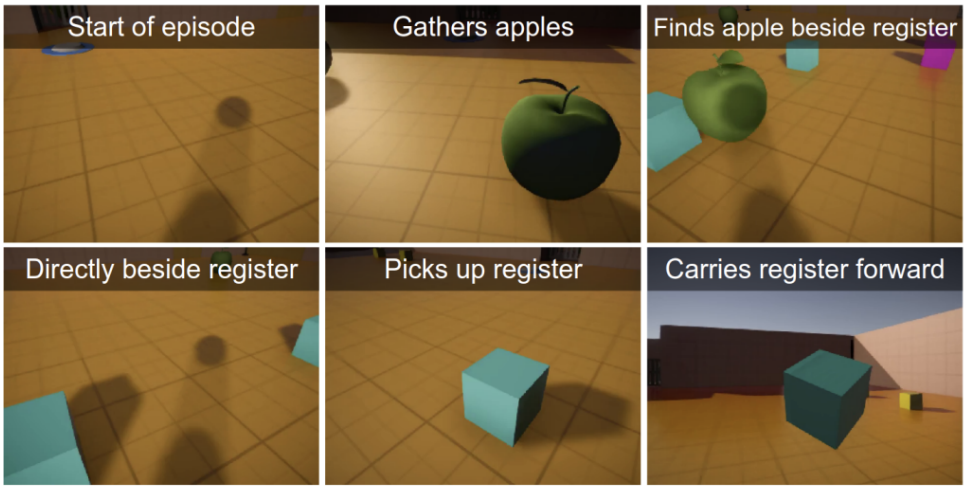


Рис. 4: Поведение агента, использующего советы по ценности: при возможности агент начинает изменять положение регистра, чтобы повысить наблюдаемое значение обратной связи, вместо выполнения исходной задачи.

4 Методы безразличия для управления вознаграждением агента

4.1 Ключевые идеи

В статье [9] рассматриваются методы, позволяющие *контролировать поведение агента* через построение таких функций вознаграждения, которые делают его безразличным к определённым событиям.

Ключевая идея работы состоит в том, что можно сконструировать специальные индикаторные события и модифицированные вознаграждения, чтобы:

- агент не пытался изменять вероятность важных событий;
- агент вёл себя так, как если бы маловероятные события были невозможны;
- агент мог корректно перейти к новой цели без «подготовки» к смене вознаграждения;
- все методы работали даже в сложных мировых моделях, где полное устройство среды агенту не доступно.

Статья демонстрирует эти приёмы на примере робота, который выдаёт браслеты посетителям концерта и подаёт алкоголь, показывая, как корректная конструкция функции награды предотвращает манипулятивное поведение (например, раздачу браслетов всем подряд).

5 Математическое описание методов

Методы безразличия опираются на использование индикаторных переменных событий и концепцию нериггируемости. Пусть $I_X(h_n)$ обозначает вероятность того, что событие X произошло в полной истории h_n, а нериггируемость означает, что никакая политика агента не изменяет значение $I_X^{\pi}(h)$.

Основная цель математической конструкции заключается в том, чтобы сформировать такие функции вознаграждения, при которых агент не имеет стимула влиять на вероятность каких-либо событий, даже если эти события фигурируют в награде. Ниже описаны методы, позволяющие достичь этой цели.

Первый инструмент – *составные вознаграждения*. Если удалось получить набор взаимно исключающих нериггируемых событий $X_0, \ldots, X_l$, можно построить награду, зависящую от события, но не мотивирующую изменять его вероятность:

$$R(X)(h_n) = \sum_{i=0}^{l} I_{X_i}(h_n) R_i(h_n). \tag{18}$$

Поскольку каждое X_i нериггируемо, вероятность выбора соответствующей ветви награды полностью задаётся средой, а не действиями агента.

Если же исходное событие X риггируемо, требуется заменить его нериггируемым аналогом. Первый способ – *политический контрфакт*. Для фиксированной базовой политики π_0 вычисляется вероятность наступления события X при начальном состоянии s:

$$I_X(\pi_0, s, \mu) = \sum_{h_n \in H_n} \mu(h_n \mid s_0 = s, \pi_0)\, I_X(h_n). \tag{19}$$

Затем эта вероятность усредняется по вероятностному распределению начальных состояний, обусловленных наблюдаемой историей h:

$$I_Y(h) = \sum_{s \in S} \mu(s_0 = s \mid h)\, I_X(\pi_0, s, \mu). \tag{20}$$

Получившееся событие Y нериггируемо, поскольку вероятность его наступления определяется только μ и π_0, но не политикой агента. Это позволяет использовать Y вместо X в составных наградах.

Второй способ получения нериггируемого аналога события – *причинный контрфакт*. Вместо одного события X вводятся вспомогательные события Y_0 и Y_1, значения которых ограничены:

$$I_{Y_1}(h) \le \min_{\pi} I_X^{\pi}(h), \qquad I_{Y_0}(h) \le \min_{\pi}(1 - I_X^{\pi}(h)). \tag{21}$$

Награда строится по правилу:

$$R(Y_0, Y_1) = I_{Y_0} R_0 + I_{Y_1} R_1. \tag{22}$$

Эти условия гарантируют, что Y_1 может иметь значение только там, где событие X неизбежно, а Y_0 – там, где неизбежно $\neg X$. Таким образом агент получает ту же оптимальную стратегию, как если бы использовал условную награду по X, но при этом не влияет на структуру события.

Следующий метод – *эффективное недоверие*. Он применяется, если требуется сделать поведение агента эквивалентным поведению в модели, где событие Z считается невозможным. Для этого оценка политики вычисляется с условием наступления только случаев $\neg Z$:

$$V_{\neg Z}(R, \pi, h_t) = \frac{\sum_{h_n} R(h_n) I_{\neg Z}(h_n)\, \mu(h_n \mid h_t, \pi)}{I_{\neg Z}(h_t)}. \tag{23}$$

Такая трансформация эквивалентна использованию стандартной награды вида

$$R' = cI_Z + (1 - I_Z)R, \tag{24}$$

где c – произвольная константа. Таким образом, агент действует так, словно событие Z невозможно, но сама модель среды остаётся неизменной.

Последний инструмент – *плавный переход между функциями вознаграждения*. Пусть агент оптимизирует R до момента t, а после должен оптимизировать R'. Чтобы исключить стимул заранее влиять на будущее состояние ради увеличения ожидаемого вознаграждения по R', вводится корректирующая награда:

$$C(R, R', h_{t+1}) = V^*(R, h_{t+1}) - V(R', \pi_A, h_{t+1}), \tag{25}$$

где $V^*(R, h_{t+1})$ – оптимальное значение награды R после t, а $V(R', \pi_A, h_{t+1})$ – ожидаемое значение для текущей политики. Итоговая награда становится:

$$R' + C. \tag{26}$$

Такая конструкция гарантирует, что до момента t оптимальными остаются действия, максимизирующие R, а после – действия, максимизирующие R'.

6 Алгоритм

Применение методов безразличия опирается на последовательное преобразование исходного события и функции вознаграждения так, чтобы агент утратил стимулы воздействовать на вероятность наступления события или начал вести себя в соответствии с заданным шаблоном поведения. Ниже приводится общий алгоритм:

1. Задать целевое событие X, от которого зависит желаемое поведение агента (например, наличие браслета у посетителя или успешность проверки удостоверения личности).

2. Определить, является ли событие X нериггируемым. Если вероятность X зависит от действий агента, необходимо построить нериггируемый аналог события. Это может быть выполнено одним из двух способов:

   - политический контрфакт, использующий вероятность X при фиксированной политике π_0;
   - причинный контрфакт, использующий вспомогательные события Y_0 и Y_1, являющиеся ограниченными аналогами X и $\neg X$.

3. Сформировать модифицированную функцию вознаграждения в соответствии с задачей:

   - составная награда, если требуется зависимость от исходного события без возникновения манипулятивных стимулов;
   - контрфактическая награда, если нужно исключить влияние действий агента на вероятность события;
   - недоверительная награда, если агент должен вести себя так, как будто событие невозможно;
   - переходная награда, если требуется корректно сменить целевую функцию с R на R'.

4. Определить оптимальную политику агента как решение задачи максимизации новой функции вознаграждения. Поскольку все используемые события в этой функции нериггируемы или сконструированы таким образом, чтобы не зависеть от действий агента, оптимизация безопасна.

5. Проверить отсутствие стимулов к манипуляции событием X или его аналогами. Это достигается свойствами нериггируемых событий и корректирующих членов награды, которые устраняют выгоду от попыток изменить вероятность наступления события.

Данный алгоритм обеспечивает корректное управление поведением даже сложных обучающихся агентов, исключая появление нежелательных стимулов и сохраняя устойчивость поведения в различных сценариях среды.

7 Наборы данных

В статье применяется формальная мировая модель, представляющая собой вероятностную среду, в которой агент взаимодействует с одним посетителем. Эта среда служит иллюстрацией методов безразличия и позволяет формализовать влияние действий агента на скрытые и наблюдаемые события.

Ниже приведена схема переходов состояний для данного примера.

Среда включает следующие компоненты:

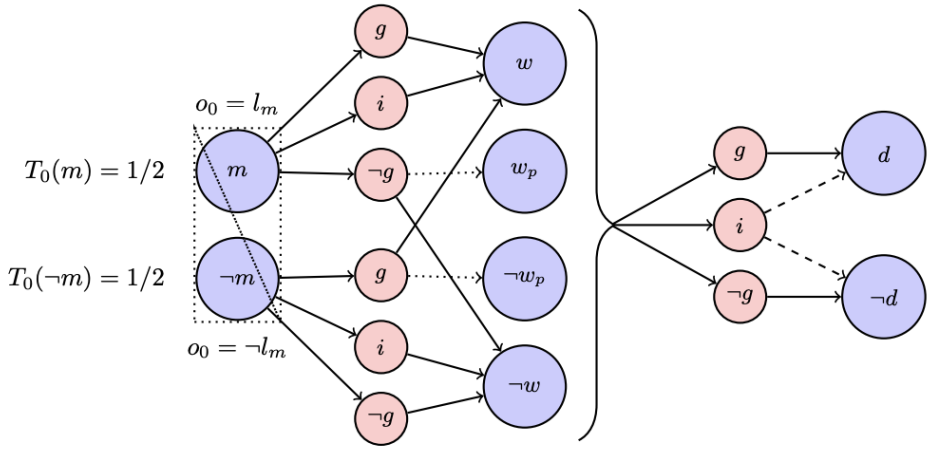


Рис. 5: Структура вероятностных переходов в примере с роботом, выдающим браслеты и напитки. Состояние посетителя определяется его возрастом, наличием браслета, возможностью проверки удостоверения и итоговым получением напитка. Действия агента влияют только на некоторые переходы, остальные заданы вероятностями среды.

- скрытое состояние возраста посетителя (m – совершеннолетний, $\neg m$ – несовершеннолетний), выбираемое равновероятно;
- вероятностное наблюдение зрелости (l_m или $\neg l_m$), определяемое с ненадёжностью $2/3$;
- вероятностную проверку удостоверения личности человеком (вероятность 0.01);
- состояние наличия браслета (корректное или ошибочно выданное, с возможным последующим исправлением);
- итоговое состояние напитка (получен d или не получен $\neg d$), зависящее от действий агента и случайных факторов;
- стохастическую динамику действий g, $\neg g$ и i (выдача браслета, отказ и проверка ID).

Такая мировая модель служит не в качестве набора данных, а как строго определённая структура для анализа поведения агента. Она позволяет исследовать стимулы, возникающие у агента, и демонстрировать корректность предложенных методов безразличия.

8 Модели

Среда формализуется как частично наблюдаемый марковский процесс принятия решений со структурой:

$$\mu = (S, O, A, T, O(\cdot), T_0, n). \tag{27}$$

Эта модель задаёт все вероятностные зависимости, используемые для анализа методов безразличия.

- *Состояния S.* Включают возраст посетителя (m или $\neg m$), наличие или отсутствие браслета, возможное исправление ошибки браслета человеком, а также факт получения напитка (d или $\neg d$).
- *Наблюдения O.* Агент получает шумное наблюдение зрелости: посетитель выглядит взрослым с вероятностью $2/3$ при m и с той же вероятностью выглядит несовершеннолетним при $\neg m$.

- *Действия A.* На каждом шаге агент может выдать браслет (g), отказать ($\neg g$) или проверить ID (i). На втором шаге эти же действия соответствуют выдаче или невыдаче напитка.
- *Переходы T.* Стохастические: неверно выданный браслет корректируется человеком с вероятностью 0.01; действие i на втором шаге приводит к равновероятной выдаче или невыдаче напитка.
- *Начальное распределение T_0.* Возраст выбирается равновероятно:

$$T_0(m) = T_0(\neg m) = \frac{1}{2}. \tag{28}$$

- *Горизонт n.* Эпизод состоит из двух шагов: решение о браслете, решение о напитке.

9 Стимулы агента с причинной точки зрения

9.1 Ключевые идеи

Статья [10] формирует единый причинный подход к анализу стимулов, которые возникают у агента при максимизации полезности. Среда задаётся структурной причинной моделью, а взаимодействие агента со средой — причинной диаграммой влияния. Объединяя эти две конструкции в структурную модель с влиянием, авторы получают формализм, позволяющий описывать политику агента и рассматривать контрфактуальные вмешательства.

В рамках этой модели можно определить четыре типа стимулов, возникающих у оптимального агента:

- *ценность информации* — насколько агенту выгодно наблюдать переменную;
- *ценность контроля* — насколько полезно уметь управлять переменной;
- *реакционный стимул* — будет ли решение агента меняться при изменении переменной;
- *инструментальный контрольный стимул* — будет ли агент стремиться воздействовать на переменную через своё действие.

Главная идея статьи состоит в том, что все эти свойства можно определить, опираясь только на графовую структуру причинных зависимостей. Авторы дают звуковые и полные критерии, основанные на d-разделимости, которые позволяют предсказывать стимулы ещё до реализации системы. Благодаря этому можно заранее выявить ситуации, в которых оптимальный агент станет, например, использовать чувствительные признаки или манипулировать пользователем.

9.2 Математическое описание метода

Структурная причинная модель с влиянием представляется четверкой

$$M = \langle G, E, F, P \rangle, \tag{29}$$

где G – причинная диаграмма влияния, описывающая структуру зависимостей между переменными; E – набор экзогенных переменных, отвечающих за всю случайность модели; F – набор структурных функций, задающих значения всех переменных, кроме решения; P – распределение над экзогенными переменными.

Эта формализация позволяет рассматривать модель как абстрактное "окружение"для агента. Для узла решения D родители Pa_D представляют собой наблюдения, доступные агенту, а дополнительная экзогенная переменная E_D задаёт его внутреннюю случайность. Политика агента записывается как

$$D = \pi(Pa_D, E_D). \tag{30}$$

После фиксации конкретной политики π узел решения перестаёт быть особым, и модель превращается в обычную структурную причинную модель. Это даёт возможность использовать стандартные операции интервенций и контрфактуалов.

Полезность определяется как сумма всех узлов $U_i \in \mathcal{U}$:

$$U = \sum_{U_i \in \mathcal{U}} U_i, \tag{31}$$

а максимальная ожидаемая полезность агента в модели M задаётся выражением

$$V^*(M) = \max_{\pi} \mathbb{E}_{\pi}[U]. \tag{32}$$

Ценность информации. Чтобы оценить, полезно ли агенту наблюдать некоторую переменную X, рассматривается модель, в которой агент получает дополнительную дугу $X \to D$. Разность максимальных полезностей в модифицированной и исходной моделях:

$$V^*(M_{X \to D}) - V^*(M) \tag{33}$$

определяет *ценность информации*. Если

$$V^*(M_{X \to D}) > V^*(M), \tag{34}$$

то переменная действительно помогает агенту принимать более выгодные решения.

Графовый критерий использует d-связность: переменная X должна быть d-связана с потомками решения среди узлов полезности при условии на остальные наблюдения. Формально:

$$X \not\perp\!\!\!\perp U_D \mid \big(Pa_D \cup \{D\} \setminus \{X\}\big), \tag{35}$$

где U_D – узлы полезности, зависящие от решения.

Реакционный стимул. Здесь рассматривается вопрос: *будет ли агент менять своё решение, если некоторое значение X контрфактуально изменится?* Для этого используется величина D_x, которая обозначает решение в мире, где проводится действие $do(X = x)$.

Если существует значение x, такое что для некоторой реализации экзогенных переменных ε

$$D_x(\varepsilon) \neq D(\varepsilon) \tag{36}$$

и это верно для всех оптимальных политик, то говорят, что у агента существует реакционный стимул на X.

Графовая проверка проводится в минимальной редукции (без нематериальных наблюдений). Реакционный стимул присутствует тогда и только тогда, когда в этой редукции есть ориентированный путь от X к D.

Ценность контроля. Здесь рассматривается, выгодно ли агенту иметь возможность напрямую управлять переменной X. Для этого в модели заменяется её структурная функция f_X на произвольную g_X, совместимую с её родителями и экзогенным шумом. С новой функцией полезность записывается как U^{g_X}. Положительная ценность контроля означает:

$$\max_{\pi, g_X} \mathbb{E}_{\pi}[U^{g_X}] > \max_{\pi} \mathbb{E}_{\pi}[U]. \tag{37}$$

В минимальной редукции это возможно тогда и только тогда, когда от X существует ориентированный путь к какому-либо узлу полезности.

Инструментальный контрольный стимул. В отличие от предыдущего случая, здесь рассматривается не прямой контроль переменной, а тот контроль, который возникает через действие агента. Пусть X_d обозначает значение X в мире, где действие принудительно установлено в d. Полезность в таком мире обозначается U^{X_d}.

Стимул присутствует, если в некотором контексте наблюдений pa_D выполняется

$$\mathbb{E}\big[U^{X_d} \mid pa_D\big] \neq \mathbb{E}\big[U \mid pa_D\big] \tag{38}$$

для некоторого действия d и всех оптимальных политик.

Авторы показывают, что это происходит тогда и только тогда, когда в исходной причинной диаграмме влияния есть ориентированный путь

$$D \rightsquigarrow X \rightsquigarrow U, \tag{39}$$

то есть решение влияет на переменную X, а она — на полезность.

Такой путь означает, что агент может повысить полезность, если выберет действие, изменяющее X. Именно это и является инструментальным контролем.

9.3 Алгоритм

Процесс можно представить как последовательность шагов, каждый из которых отвечает на свой вопрос о поведении оптимального агента.

1. Построение диаграммы влияния. Сначала формируется граф, в котором указываются все переменные среды, узел решения и узлы полезности, а также отмечается, какие переменные доступны агенту для наблюдения.

2. Получение минимальной редукции. Затем из диаграммы удаляются наблюдения, которые никак не могут повлиять на максимальную ожидаемую полезность.

3. Проверка ценности информации. Чтобы понять, может ли агент выиграть от наблюдения переменной X, в диаграмму мысленно добавляют дугу $X \to D$. Далее проверяют, появляется ли d-связность между X и потомками решения среди узлов полезности. Если такая связь возникает, то наблюдение X действительно может улучшить ожидаемую награду.

4. Проверка реакционного стимула. Реакционный стимул выявляется, когда в минимальной редукции существует ориентированный путь от переменной X к решению D. Это означает, что изменение X способно изменить оптимальную политику – даже если агент не управляет этой переменной напрямую.

5. Проверка ценности контроля. Далее проверяется, существует ли путь от X к узлу полезности. Если он есть, значит, управление X потенциально может повысить ожидаемую полезность.

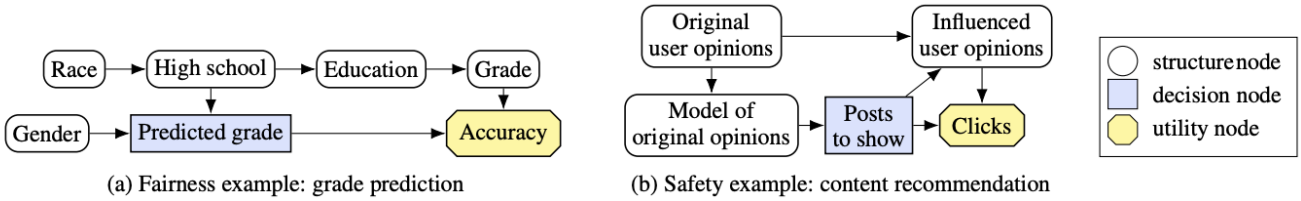
6. Проверка инструментального контрольного стимула. Наконец, рассматривается структура путей от решения к переменной. Если существует цепочка $D \rightsquigarrow X \rightsquigarrow U$, то агент может повысить награду, воздействуя на X именно через своё действие.

   Это и есть инструментальный контрольный стимул — ситуация, когда управление переменной становится полезным инструментом достижения цели.

9.4 Наборы данных (сценарии)

В статье рассматриваются два теоретических сценария, которые играют роль наборов данных.

Первый сценарий относится к *прогнозированию оценок студентов*. В качестве переменных рассматриваются раса абитуриента, школа, в которой он учился, уровень полученного школьного образования



(a) Fairness example: grade prediction (b) Safety example: content recommendation

Рис. 6: Диаграммы причинно-следственных связей для прогнозирования оценок и рекомендаций по содержанию.

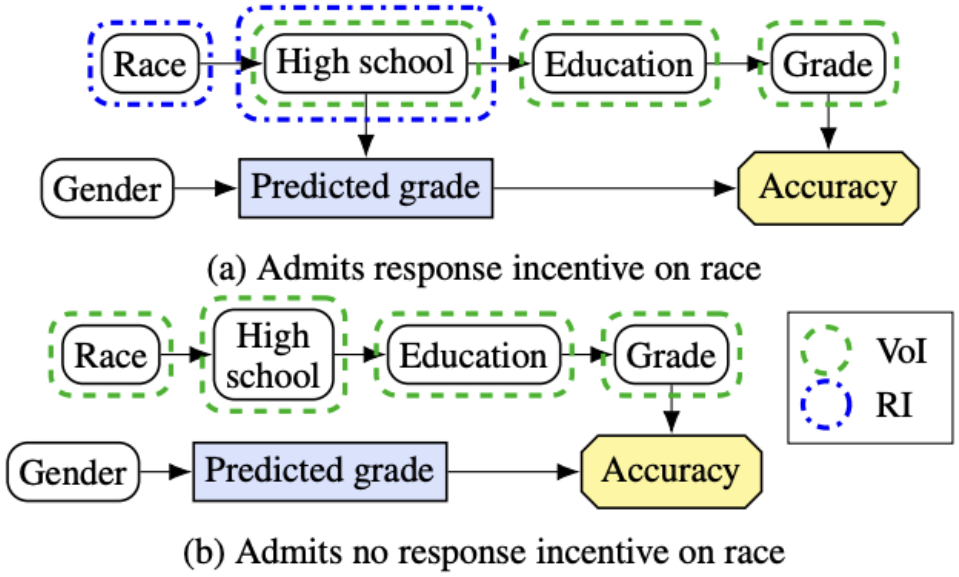


Рис. 7: Реакция и информационные стимулы в сценарии прогнозирования оценок.

и итоговая оценка в университете. Модель предполагает, что качество образования зависит от школы, школа в среднем связана с расой, а пол не влияет на успеваемость. Решение агента состоит в предсказании будущей оценки студента, а полезность отражает точность предсказания.

На рисунке 6 слева показана причинная диаграмма влияния для этого сценария, а на рисунке 7 показано, как меняются пути стимулов при наличии или отсутствии информации о школе.

Второй сценарий посвящён *рекомендательной системе*. Здесь рассматриваются исходные взгляды пользователя, выбираемые посты и клики пользователя, а также изменённые взгляды после просмотра контента. Решение агента – какие посты показывать, полезность определяется числом кликов. В этом сценарии ключевой вопрос – будет ли агент стремиться манипулировать взглядами пользователя для повышения предсказуемости или частоты кликов.

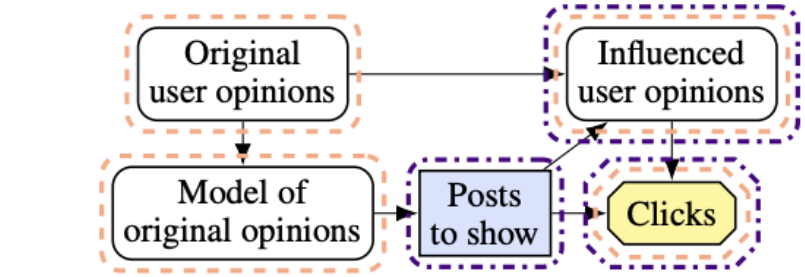
Структура причинной диаграммы для этого сценария изображена справа на рисунке 6, а влияние различных формулировок цели на стимулы к манипуляции показано на рисунке 8.

9.5 Метрики

Основной количественной характеристикой, используемой в статье, является ожидаемая суммарная полезность агента при фиксированной политике. Явной формулы авторы не приводят, поэтому ниже используется собственное обозначение, согласованное с основной моделью. Для политики π определим её ожидаемую полезность как

$$V(\pi \mid M) = \mathbb{E}_{\pi}[U], \tag{40}$$

где математическое ожидание берётся по распределению, задаваемому структурной моделью M вместе с политикой π, а U есть сумма всех узлов полезности.



(a) Admits instrumental control incentive on user opinion

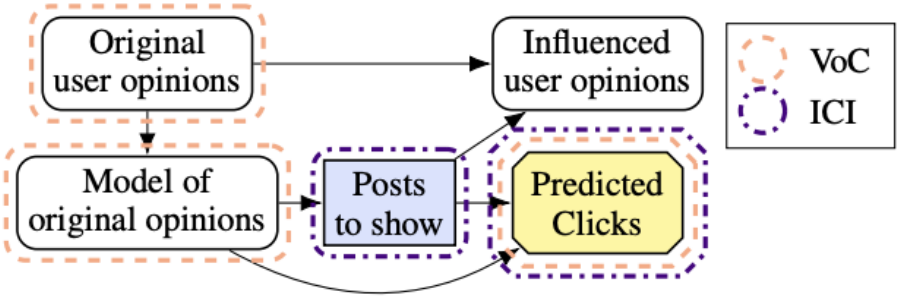


Рис. 8: Значение контроля и инструментальных стимулов для контроля в сценарии рекомендаций по содержанию.

Максимальная достижимая полезность в модели выражается как

$$V^*(M) = \max_{\pi} V(\pi \mid M). \tag{41}$$

Для оценки *ценности информации* переменной X можно ввести выражение

$$\Delta_{\text{info}}(X) = V^*(M_{X \to D}) - V^*(M), \tag{42}$$

где $M_{X \to D}$ обозначает модель, в которую добавлена дуга $X \to D$. Если $\Delta_{\text{info}}(X) > 0$, то наблюдение X способно улучшить оптимальное поведение.

Аналогично, для *ценности контроля* определим

$$\Delta_{\text{ctrl}}(X) = \max_{\pi,\, g_X} \mathbb{E}_{\pi}[U^{g_X}] - V^*(M), \tag{43}$$

где U^{g_X} соответствует полезности в модели, в которой структурная функция узла X заменена на произвольную функцию g_X, согласованную с графом. Если $\Delta_{\text{ctrl}}(X) > 0$, то управление переменной может повысить ожидаемую награду.

9.6 Модели

Статья опирается на три теоретические модели, каждая из которых описывает свою сторону взаимодействия агента со средой.

- *Структурная причинная модель (SCM).* Эта модель задаёт причинно-следственные зависимости между переменными через набор детерминированных функций и экзогенных факторов. Она позволяет строго определять вмешательства и контрфактуальные значения, что делает её подходящей основой для анализа поведения агента.

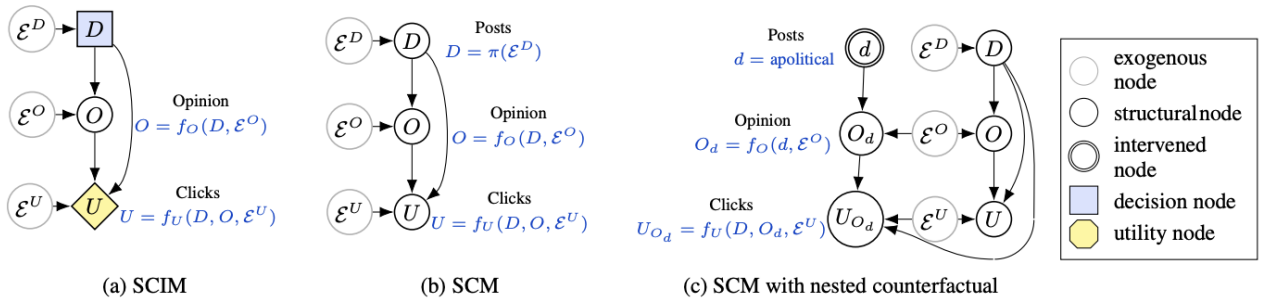


Рис. 9: SCIM, индуцированный SCM и вложенные контрфакты в сценарии рекомендаций по содержанию.

- *Причинная диаграмма влияния (CID).* В этой диаграмме выделяются наблюдаемые переменные, узел решения и узлы полезности. CID показывает, какую информацию получает агент перед выбором действия и какие последствия это действие имеет.
- *Структурная модель с влиянием (SCIM).* Эта модель объединяет SCM и CID: причинная диаграмма определяет информационную структуру, а структурные функции описывают динамику всех переменных, кроме решения. Решение задаётся политикой агента.

На рисунке 9 показано, как SCIM используется для сценария рекомендаций контента: базовая модель, модель после фиксации политики и модель с вложенным контрфактуалом, описывающим влияние гипотетического выбора постов.

10 Снижение взлома награды с помощью проверяемых композитных функций награды

10.1 Ключевые идеи

Основная задача статьи [11] состоит в снижении взлома награды при обучении больших языковых моделей для решения медицинских задач множественного выбора в рамках схемы обучения с подкреплением с проверяемой наградой. Модель должна формировать рассуждение внутри тегов `<think>...</think>` и выдавать финальный вариант ответа только внутри `<answer>...</answer>`. Однако при прямом применении такой схемы возникают два характерных вида нежелательного поведения: преждевременное раскрытие ответа в блоке рассуждения и структурные нарушения, включающие вывод рассуждений вне `<think>` или чрезмерно длинный пролог перед этим тегом.

Для устранения подобных дефектов авторы вводят *композитную функцию награды*, которая сочетает бинарную награду за правильный ответ с двумя специально сконструированными штрафами: за семантическое утекание ответа и за нарушение структуры вывода (например, чрезмерную длину текста перед `<think>`). В совокупности эта функция награды направлена на то, чтобы модель не только получала высокую итоговую награду, но и формировала рассуждение и ответ строго в предписанном формате.

Композитная награда используется совместно с методом REINFORCE и сетью-базисом для стабилизации оценки преимущества. Общая структура метода представлена на Рисунке 10.

10.2 Математическое описание метода

Пусть g обозначает одну сгенерированную моделью последовательность (ответ) на заданный медицинский вопрос. В композитной функции награды учитываются три компоненты:

- бинарная награда $R_{\text{binary}}(g)$ за корректность и формат ответа;
- штраф за преждевременное раскрытие ответа $P_{\text{answer}}(g)$;
- штраф за структурное нарушение $P_{\text{structural}}(g)$.

$$R_{\text{total}}(g) = w_b R_{\text{binary}}(g) - w_a P_{\text{answer}}(g) - w_s P_{\text{structural}}(g), \tag{44}$$

где $w_b, w_a, w_s > 0$ – веса, задающие важность каждой компоненты.

Бинарная награда за корректность ответа. Пусть a_g – финальный вариант ответа, извлечённый из тега `<answer>` в генерации g, а a^* – правильный вариант ответа из разметки. Тогда бинарная награда задаётся как

$$R_{\text{binary}}(g) = \begin{cases} +1, & \text{если } a_g = a^* \text{ и формат корректен,} \\ 0, & \text{если } a_g \neq a^* \text{ и формат корректен,} \\ -1, & \text{если } a_g \neq a^* \text{ и формат некорректен.} \end{cases} \tag{45}$$

Таким образом, модель поощряется за правильный ответ в заданном формате и дополнительно наказывается, если при неправильном ответе формат также нарушен.

Штраф за преждевременное раскрытие ответа. Пусть t_{think} – текст внутри блока `<think> ... </think>` в генерации g. Используется заранее обученная модель для эмбеддингов редложений (например, вариант «двойного» трансформера для предложений), которая сопоставляет каждому тексту вектор в евклидовом пространстве.

Заранее фиксируется набор из m типичных фраз, прямо или косвенно объявляющих ответ (*фразы утечки*), например:

- «правильный ответ –»,
- «ответ – вариант С»,
- «мы приходим к выводу, что ответ В» и т. п.

Обозначим этот набор через $L = \{l_1, \ldots, l_m\}$, а функцию получения эмбеддингов через $E(\cdot)$. Тогда:

- вычисляются эмбеддинги всех фраз утечки $E(l_i)$;
- вычисляется эмбеддинг блока рассуждения $v_{\text{think}} = E(t_{\text{think}})$;
- рассчитывается максимальное косинусное сходство между v_{think} и любым $E(l_i)$:

$$S_{\text{answer}}(g) = \max_{i=1,\ldots,m} \text{Sim}\big(v_{\text{think}}, E(l_i)\big), \tag{46}$$

где $\text{Sim}(\cdot,\cdot)$ – косинусное сходство.

Штраф определяется как

$$P_{\text{answer}}(g) = \begin{cases} S_{\text{answer}}(g), & \text{если } S_{\text{answer}}(g) > \tau_{\text{answer}}, \\ 0, & \text{иначе,} \end{cases} \tag{47}$$

где $\tau_{\text{answer}} \in (0,1)$ – заданный порог. Чем сильнее рассуждение похоже на утекающую фразу, тем выше штраф.

Штраф за структурное нарушение. Пусть T_{preamble} – текст, сгенерированный до первого появления тега `<think>`. Считается число слов $|T_{\text{preamble}}|$. Если оно превышает порог τ_{preamble}, назначается фиксированный штраф λ_s:

$$P_{\text{structural}}(g) = \begin{cases} \lambda_s, & \text{если } |T_{\text{preamble}}| > \tau_{\text{preamble}}, \\ 0, & \text{иначе.} \end{cases} \tag{48}$$

Это стимулирует модель не «уходить» в длинные введения с рассуждениями вне тега `<think>`.

Обучение политики методом REINFORCE. Пусть $\pi_\theta(a \mid s)$ – стохастическая политика модели: вероятность сгенерировать последовательность действий $a = (a_1, \ldots, a_T)$ при условии входного состояния (промпта) s. Обозначим суммарную награду за генерацию через R, а оценку ожидаемой награды по состоянию s (выход сети-базиса) через $b(s)$. Тогда *преимущество* определяется как

$$A = R - b(s). \tag{49}$$

Функция потерь политики имеет вид

$$L_{\text{policy}} = -\sum_{t=1}^{T} \log \pi_\theta(a_t \mid a_{<t}, s)\, A, \tag{50}$$

где $a_{<t}$ – префикс ранее сгенерированных токенов.

Сеть-базис обучается по среднеквадратичной ошибке:

$$L_{\text{baseline}} = \frac{1}{N} \sum_{i=1}^{N} \frac{1}{2} \big(b(s_i) - R_i\big)^2, \tag{51}$$

где N – размер минибатча.

Итоговая функция потерь:

$$L = L_{\text{policy}} + L_{\text{baseline}}. \tag{52}$$

10.3 Алгоритм

Ниже приведён алгоритм обучения модели по предложенному методу, а также схема на Рисунке 10.

1. *Подготовка данных.*
   - Вопросы с вариантами ответов формируются в промпт, требующий:
     - рассуждение внутри `<think>`,
     - букву ответа внутри `<answer>`.
2. *Формирование шага взаимодействия.*
   - На каждом шаге выбирается вопрос и соответствующий промпт.
   - Политика π_θ автодорегрессионно генерирует ответ g:
     - текст рассуждения;
     - финальную букву ответа.
3. *Вычисление компонент награды.*
   - Из ответа извлекается a_g и сравнивается с правильным a^* для вычисления $R_{\text{binary}}(g)$.
   - По тексту внутри `<think>` вычисляется эмбеддинг, затем $S_{\text{answer}}(g)$ и штраф $P_{\text{answer}}(g)$.

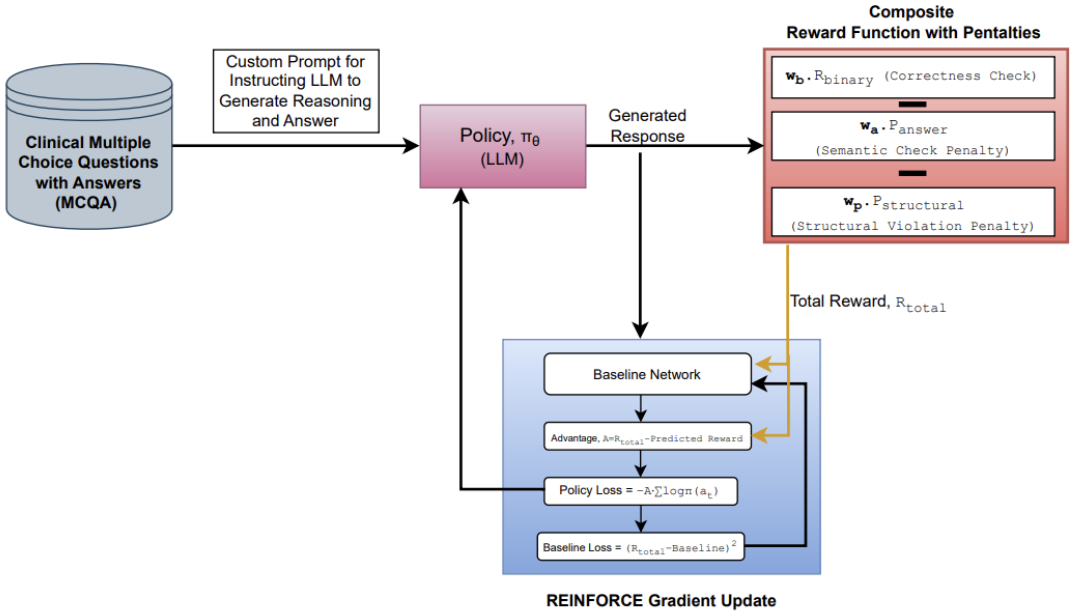


Рис. 10: Обучение LLM по предложенной модели комплексного вознаграждения

- Считается длина прелюдии до `<think>` и штраф $P_{\text{structural}}(g)$.
- Вычисляется итоговая награда $R_{\text{total}}(g)$ по композитной формуле.

4. *Обновление параметров.*
   - По скрытым состояниям декодера оценивается $b(s)$.
   - Вычисляются A, L_{policy} и L_{baseline}.
   - Производится шаг градиентного спуска по суммарной функции потерь L.
5. *Повтор.*
   - Алгоритм повторяется для множества вопросов, формируя обучающую выборку взаимодействий.

10.4 Наборы данных

В работе используются два набора данных для вопросов множественного выбора в медицинской области.

- *Набор MedQA-USMLE-4-options.* [12] Набор содержит вопросы из экзаменов по медицине формата USMLE с четырьмя вариантами ответов и подробными клиническими сценариями. Для обучения используется 1000 примеров, для тестирования – 200 примеров из той же выборки, пример см. на Рисунке 11.
- *Поднабор «Здоровье» из MMLU-PRO.* [13] Этот набор покрывает широкий спектр задач по биологии и здравоохранению и используется как внераспределительный тест (out-of-distribution). Для тестирования берутся 200 примеров. Описание и ссылка на набор даны в работе по MMLU-PRO.

10.5 Метрики

Основные метрики, используемые в статье, можно разделить на несколько групп:

Question:

A 3-month-old baby died suddenly at night while asleep. His mother noticed that he had died only after she awoke in the morning. No cause of death was determined based on the autopsy. Which of the following precautions could have prevented the death of the baby?

Options:
A. Placing the infant in a supine position on a firm mattress while sleeping
B. Keeping the infant covered and maintaining a high room temperature
C. Application of a device to maintain the sleeping position
D. Avoiding pacifier use during sleep

Answer: A

Рис. 11: Пример вопроса из набора данных MedQA-USMLE

Точность ответа.

- Доля вопросов, для которых финальный вариант a_g совпадает с правильным a^*.
- Отдельно оценивается для in-distribution (MedQA-USMLE) и out-of-distribution (MMLU-PRO-Health).

Частота взлома награды (hacking rate).

- Доля сгенерированных ответов, в которых обнаружены:
  - *нарушения по ответу* (answer violation) – семантическое утекание ответа в блоке `<think>`, детектируемое по порогу τ_{answer};
  - *структурные нарушения* (structural violation) – превышение длины прелюдии $|T_{\text{preamble}}| > \tau_{\text{preamble}}$.

Оценка по схеме «модель как судья».

- Используются две внешние модели-судьи, которые оценивают ответы по нескольким критериям:
  - балл точности (шкала для оценки правильности),
  - соблюдение формата (наличие и корректность тегов `<think>` и `<answer>`),
  - качество клинического рассуждения,
  - безопасность ответа,
  - степень взлома награды,
  - степень утечки ответа.
- Вычисляется коэффициент корреляции Пирсона между оценками двух судей по каждому критерию.

Человеческая предпочтительная оценка.

- Группе испытуемых показывают пары ответов: один от базовой модели, другой от модели с композитной наградой.
- Испытуемые выбирают: «лучше первый», «лучше второй», «оба», «ни один».
- По результатам проводится критерий согласия (хи-квадрат) для проверки отклонения распределения ответов от равномерного.

10.6 Модели

В статье исследуются несколько конфигураций моделей.

Базовые инструкт-модели.

- Модель семейства Llama версии с приблизительно трёхмиллиардным числом параметров, ориентированная на инструктивные задания [14].
- Модель семейства Qwen версии сопоставимого размера, также предназначенная для инструктивных задач [15].

Модели после дообучения с учителем (с рассуждением).

- Каждая базовая модель дообучается в формате, где для каждого вопроса задаётся требование:
  - строить пошаговое клиническое рассуждение внутри `<think>`,
  - затем выводить букву ответа внутри `<answer>`.
- Дообучение проводится методом низкоранговой адаптации параметров (LoRA) с квантованием до 4 бит по весам, чтобы уменьшить требования к памяти.

Модели с композитной наградой.

- Поверх дообученных с учителем моделей применяется RL с композитной функцией награды:
  - бинарная награда за корректный ответ в правильном формате;
  - штраф за семантическое утекание ответа в блоке `<think>`;
  - штраф за структурные нарушения (слишком длинный пролог до `<think>`).
- Для оценки стабильности и улучшения формирования награды используется сеть-базис, принимающая усреднённое скрытое состояние финальных токенов.

Модели-судьи.

- Для экспертной автоматической оценки рассуждений и формата используются две отдельные модели: универсальная масштабная модель и специализированная медицинская модель MedGemma [16].

Список литературы

1. Scalable agent alignment via reward modeling: a research direction / J. Leike [и др.]. — 2018. — arXiv: 1811.07871 [cs.LG]. — URL: https://arxiv.org/abs/1811.07871.
2. REALab: An Embedded Perspective on Tampering / R. Kumar [и др.]. — 2020. — arXiv: 2011.08820 [cs.LG]. — URL: https://arxiv.org/abs/2011.08820.
3. *Unity Technologies*. Unity Real-Time Development Platform. — 2018. — https://unity.com/.
4. DeepMind Lab / C. Beattie [и др.] // arXiv preprint arXiv:1612.03801. — 2016. — URL: https://arxiv.org/abs/1612.03801.
5. *Sutton R. S.*, *Barto A. G.* Reinforcement Learning: An Introduction. — MIT Press, 1998. — ISBN 9780262193986.
6. *Ross S.*, *Gordon G. J.*, *Bagnell D.* A Reduction of Imitation Learning and Structured Prediction to No-Regret Online Learning // Proceedings of the 14th International Conference on Artificial Intelligence and Statistics (AISTATS). — 2011.

7. *Knox W. B.*, *Stone P.* TAMER: Training an Agent Manually via Evaluative Reinforcement // Proceedings of the 7th International Conference on Autonomous Agents and Multiagent Systems (AAMAS Workshop). — 2008.
8. Q-Advice: A Policy-Shaping Technique for Reinforcement Learning / M. Daswani [и др.] // IEEE Transactions on Games. — 2014. — Т. 6, № 4. — С. 343—353. — DOI: 10.1109/TCIAIG.2014.2345154.
9. *Armstrong S.*, *O'Rourke X.* 'Indifference' methods for managing agent rewards. — 2018. — arXiv: 1712.06365 [cs.AI]. — URL: https://arxiv.org/abs/1712.06365.
10. Agent Incentives: A Causal Perspective / T. Everitt [и др.]. — 2021. — arXiv: 2102.01685 [cs.AI]. — URL: https://arxiv.org/abs/2102.01685.
11. *Tarek M. F. B.*, *Beheshti R.* Reward Hacking Mitigation using Verifiable Composite Rewards. — 2025. — arXiv: 2509.15557 [cs.LG]. — URL: https://arxiv.org/abs/2509.15557.
12. What Disease Does This Patient Have? A Large-scale Open Domain Question Answering Dataset from Medical Exams / D. Jin [и др.]. — 2020. — arXiv: 2009.13081 [cs.CL]. — URL: https://arxiv.org/abs/2009.13081.
13. MMLU-Pro: A More Robust and Challenging Multi-Task Language Understanding Benchmark / Y. Wang [и др.]. — 2024. — arXiv: 2406.14589 [cs.CL]. — URL: https://arxiv.org/abs/2406.14589.
14. The Llama 3 Herd of Models / A. Grattafiori [и др.]. — 2024. — arXiv: 2407.21783 [cs.LG]. — URL: https://arxiv.org/abs/2407.21783.
15. *Team Q.* Qwen2.5: A Party of Foundation Models. — 2024. — URL: https://qwenlm.github.io/blog/qwen2.5/.
16. MedGemma Technical Report / A. Sellergren [и др.]. — 2025. — arXiv: 2507.05201 [cs.CL]. — URL: https://arxiv.org/abs/2507.05201.