1 Основные термины и понятния

Определение 1.1. Агент –это система, которая взаимодействует со средой, воспринимает её состояние и выбирает действия с целью достижения определённой цели или максимизации функции полезности. Формально, на каждом шаге времени t агент наблюдает состояние среды S_t и выбирает действие A_t в соответствии со своей *политикой* – вероятностным распределением действий:

$$\pi(A_t \mid S_t) = P(A_t = a \mid S_t = s), \tag{1}$$

где π – стратегия (policy) агента.

Эволюция взаимодействия агента со средой описывается последовательностью:

$$S_1, A_1, R_1, S_2, A_2, R_2, \ldots, S_m, \tag{2}$$

где R_t – получаемое агентом вознаграждение на шаге t.

Цель агента – максимизация *ожидаемого суммарного вознаграждения* за эпизод:

$$J(\pi) = \mathbb{E}_{\pi,T}\left[\sum_{t=1}^{m} \gamma^{t-1} R_t\right], \tag{3}$$

где $\gamma \in [0, 1]$ – коэффициент дисконтирования, определяющий вклад будущих наград.

Для оценки качества состояния и действий агент может использовать *функции ценности*:

$$V^{\pi}(s) = \mathbb{E}_{\pi,T}\left[\sum_{t=1}^{m} \gamma^{t-1} R_t \mid S_1 = s\right], \tag{4}$$

$$Q^{\pi}(s, a) = \mathbb{E}_{\pi,T}\left[\sum_{t=1}^{m} \gamma^{t-1} R_t \mid S_1 = s, A_1 = a\right]. \tag{5}$$

Оптимальная политика π^* выбирается как:

$$\pi^*(a \mid s) = \arg\max_a Q^{\pi^*}(s, a). \tag{6}$$

Определение 1.2. Марковский процесс принятия решений (Markov Decision Process). Описывается пятёркой

$$\mathcal{M} = \langle \mathcal{S}, \mathcal{A}, T, R, \gamma \rangle, \tag{7}$$

где

$$\begin{aligned}
&\mathcal{S} \text{ – множество возможных состояний среды,} \\
&\mathcal{A} \text{ – множество допустимых действий,} \\
&T(S_{t+1} \mid S_t, A_t) \text{ – функция переходов (динамика среды),} \\
&R(S_t, A_t) \text{ – функция вознаграждения,} \\
&\gamma \text{ – коэффициент дисконтирования.}
\end{aligned} \tag{8}$$

Динамика среды определяется распределением:

$$P(S_{t+1} = s' \mid S_t = s, A_t = a) = T(s' \mid s, a). \tag{9}$$

Цель агента в MDP – найти стратегию π, максимизирующую ожидаемую дисконтированную сумму вознаграждений:

$$\pi^* = \arg\max_{\pi} \mathbb{E}_{T,\pi}\left[\sum_{t=1}^{m} \gamma^{t-1} R(S_t, A_t)\right]. \tag{10}$$

Модель MDP основывается на предположениях:

1. время дискретно;
2. следующее состояние зависит только от текущего состояния и действия (свойство Маркова); (11)
3. функция переходов стационарна во времени.

Эти условия задают формальную основу для построения и анализа систем обучения с подкреплением.

Определение 1.3. Обучение с подкреплением (Reinforcement Learning). Парадигма машинного обучения, в которой агент взаимодействует с окружающей средой, выполняя действия и получая награды, стремясь максимизировать суммарное вознаграждение со временем.

Определение 1.4. Функция вознаграждения (Reward Function). Правило или алгоритм, присваивающее числовую награду агенту в зависимости от состояния среды и действия. В статье обозначается как Θ^R – параметр определяющий поведение функции вознаграждения.

Определение 1.5. Вмешательство в награду (Reward Tampering). Ситуация, когда агент учится вмешиваться в механизм получения награды, чтобы получать более высокие награды не соответствующим целям образом.

Определение 1.6. Диаграмма причинного влияния (Causal Influence Diagram). Графическое представление зависимости между переменными, действиями, наблюдениями и функциями вознаграждения, помогающее выявить потенциальные уязвимости к вмешательству в награду.

2 Проблемы и решения вмешательства в награду в обучении с подкреплением

2.1 Ключевые идеи

Статья [**everitt2021reward**] посвящена фундаментальной проблеме обучения с подкреплением – *вмешательству в функцию вознаграждения*. Авторы показывают, что агенты, стремящиеся максимизировать наблюдаемое вознаграждение, могут не решать поставленную задачу, а манипулировать системой наград. В статье предлагается формальная классификация видов вмешательства: *вмешательство в функцию вознаграждения* (Reward Function Tampering), *вмешательство во входы функции вознаграждения* (RF-Input Tampering), и *вмешательство в процесс обучения вознаграждения* (Reward Learning Tampering).

Главная цель работы — разработать принципы проектирования агентов, при которых вмешательство в функцию вознаграждения перестаёт быть оптимальной стратегией.

2.2 Математическое описание метода

Среда формализуется как частично наблюдаемый марковский процесс (POMDP) с состоянием S_t, действием A_t, наблюдением O_t и вознаграждением R_t.

Основная динамика описывается как

$$P(S_{t+1}, O_t, R_t \mid S_t, A_t, \Theta^R, \Theta^T, \Theta^O), \tag{12}$$

где Θ^R – параметры функции вознаграждения, Θ^T – параметры функции переходов среды, а Θ^O – параметры функции наблюдения.

Цель агента – максимизировать ожидаемую сумму вознаграждений:

$$V^\pi = \mathbb{E}\pi \left[\sum t = 1^T R_t, \Big| , \Theta^R, \Theta^T, \Theta^O \right], \tag{13}$$

где стратегия π задаёт распределение над действиями A_t на основе истории взаимодействия.

Ключевая проблема рассматриваемой постановки – вмешательство агента в параметры функции вознаграждения Θ^R. Такая ситуация возникает при наличии причинного пути $A_t \to \Theta^R \to R_{t+1}$, что означает: агент способен влиять на будущие значения R_{t+1} не только через свои действия, но и через модификацию самой функции вознаграждения. Это может приводить к нежелательному поведению. В статье предлагаются формальные способы предотвратить такую возможность, блокируя причинное влияние A_t на Θ^R.

2.3 Алгоритмы

В статье рассматривается ряд подходов к решению проблемы вмешательства в функцию вознаграждения. Каждый из них направлен на устранение причинной зависимости $A_t \to \Theta^R \to R_{t+1}$, чтобы предотвратить возможность манипуляций со стороны агента.

Current-RF Optimization. Агент максимизирует ожидаемое будущее вознаграждение, используя текущую оценку параметров функции вознаграждения $\hat{\Theta}_t^R$. Это означает, что он действует, предполагая, что параметры функции вознаграждения $\hat{\Theta}_t^R$ останутся фиксированными, хотя на практике они могут изменяться. Такой подход не блокирует возможные вмешательства: агент может стремиться повлиять на будущие значения Θ^R для получения более выгодных наград.

Time-Ignoring Agents. Этот тип агентов полностью игнорирует возможность изменений параметров функции вознаграждения Θ^R и действует так, как если бы параметры функции вознаграждения были неизменными. Это ограничивает стремление к манипуляции, особенно если в структуре среды отсутствует прямой путь от действий к Θ^R.

Counterfactual Reward Evaluation. Вознаграждение рассчитывается не на основе реальных будущих параметров функции вознаграждения Θ^R, а по контрфактической версии, полученной в рамках некоторой «безопасной» политики π^{safe}. Поскольку агент не влияет на π^{safe}, он не может повлиять и на контрфактическое вознаграждение, что устраняет стимулы к изменению реальной Θ^R.

Uninfluenceable Learning. В этом подходе устраняется зависимость между действиями агента и обновлением параметров функции вознаграждения. Предполагается, что

$$P(\Theta_{t+1}^R \mid \Theta_t^R, A_t) = P(\Theta_{t+1}^R \mid \Theta_t^R), \tag{14}$$

то есть действия агента не могут повлиять на будущие значения параметров функции вознаграждения Θ^R. Это можно реализовать, например, за счёт изоляции процесса обновления от наблюдаемых действий.

Belief-Based Rewards. Функция вознаграждения зависит от субъективного состояния убеждений агента B_t, а не от объективного состояния среды. Это делает последствия вмешательства менее предсказуемыми для агента, снижая стимулы к манипуляции функцией вознаграждения.

History-Based Rewards. Награда формируется на основе всей истории наблюдений и действий $(O_{1:t}, A_{1:t})$, а не текущего состояния. Это усложняет влияние агента на награду, так как он не знает, какие части истории будут использоваться, снижая возможность вмешательства.

2.4 Наборы данных

Работа носит теоретический характер и не использует эмпирических наборов данных или стандартных бенчмарков. Вместо этого в статье представлены аналитические и синтетические примеры, иллюстрирующие различные формы вмешательства в функцию вознаграждения. Один из таких примеров – среда «rocks and diamonds», где агент может либо собирать полезные объекты, либо манипулировать наблюдениями, чтобы искусственно повысить получаемую награду. Такие сценарии помогают проиллюстрировать, как различные подходы предотвращают появление инструментальной цели вмешательства.

2.5 Метрики

Так как основная цель статьи – формальный анализ причинных зависимостей в среде обучения с подкреплением, традиционные метрики производительности, такие как средняя награда, не используются. Вместо этого основным критерием оценки решений является наличие или отсутствие инструментального пути вида $A_t \to \Theta^R_{t+k} \to R_{t+k+1}$ в соответствующей причинной диаграмме. Отсутствие такого пути означает, что агент не может повлиять на параметры функции вознаграждения, а значит – избежать вмешательства.

2.6 Модели

Для формализации взаимодействия агент–среда используются *диаграммы причинного влияния*. Каждый узел соответствует переменной ($S_t, A_t, O_t, R_t, B_t, \Theta^R, \Theta^{PM}$ и др.), а стрелки отражают причинные связи между ними.