1 Основные термины и понятния

Определение 1.1. Агент –это система, которая взаимодействует со средой, воспринимает её состояние и выбирает действия с целью достижения определённой цели или максимизации функции полезности. Формально, на каждом шаге времени t агент наблюдает состояние среды S_t и выбирает действие A_t в соответствии со своей *политикой* – вероятностным распределением действий:

$$\pi(A_t \mid S_t) = P(A_t = a \mid S_t = s), \tag{1}$$

где π – стратегия (policy) агента.

Эволюция взаимодействия агента со средой описывается последовательностью:

$$S_1, A_1, R_1, S_2, A_2, R_2, \ldots, S_m, \tag{2}$$

где R_t – получаемое агентом вознаграждение на шаге t.

Цель агента – максимизация *ожидаемого суммарного вознаграждения* за эпизод:

$$J(\pi) = \mathbb{E}_{\pi,T}\left[\sum_{t=1}^{m} \gamma^{t-1} R_t\right], \tag{3}$$

где $\gamma \in [0, 1]$ – коэффициент дисконтирования, определяющий вклад будущих наград.

Для оценки качества состояния и действий агент может использовать *функции ценности*:

$$V^{\pi}(s) = \mathbb{E}_{\pi,T}\left[\sum_{t=1}^{m} \gamma^{t-1} R_t \mid S_1 = s\right], \tag{4}$$

$$Q^{\pi}(s, a) = \mathbb{E}_{\pi,T}\left[\sum_{t=1}^{m} \gamma^{t-1} R_t \mid S_1 = s, A_1 = a\right]. \tag{5}$$

Оптимальная политика π^* выбирается как:

$$\pi^*(a \mid s) = \arg\max_a Q^{\pi^*}(s, a). \tag{6}$$

Определение 1.2. Марковский процесс принятия решений (Markov Decision Process). Описывается пятёркой

$$\mathcal{M} = \langle \mathcal{S}, \mathcal{A}, T, R, \gamma \rangle, \tag{7}$$

где

$$\begin{aligned}
&\mathcal{S} \text{ – множество возможных состояний среды,} \\
&\mathcal{A} \text{ – множество допустимых действий,} \\
&T(S_{t+1} \mid S_t, A_t) \text{ – функция переходов (динамика среды),} \\
&R(S_t, A_t) \text{ – функция вознаграждения,} \\
&\gamma \text{ – коэффициент дисконтирования.}
\end{aligned} \tag{8}$$

Динамика среды определяется распределением:

$$P(S_{t+1} = s' \mid S_t = s, A_t = a) = T(s' \mid s, a). \tag{9}$$

Цель агента в MDP – найти стратегию π, максимизирующую ожидаемую дисконтированную сумму вознаграждений:

$$\pi^* = \arg\max_{\pi} \mathbb{E}_{T,\pi}\left[\sum_{t=1}^{m} \gamma^{t-1} R(S_t, A_t)\right]. \tag{10}$$

Модель MDP основывается на предположениях:

1. время дискретно;
2. следующее состояние зависит только от текущего состояния и действия (свойство Маркова); (11)
3. функция переходов стационарна во времени.

Эти условия задают формальную основу для построения и анализа систем обучения с подкреплением.

Определение 1.3. Обучение с подкреплением (Reinforcement Learning). Парадигма машинного обучения, в которой агент взаимодействует с окружающей средой, выполняя действия и получая награды, стремясь максимизировать суммарное вознаграждение со временем.

Определение 1.4. Функция вознаграждения (Reward Function). Правило или алгоритм, присваивающее числовую награду агенту в зависимости от состояния среды и действия. В статье обозначается как Θ^R – параметр определяющий поведение функции вознаграждения.

Определение 1.5. Вмешательство в награду (Reward Tampering). Ситуация, когда агент учится вмешиваться в механизм получения награды, чтобы получать более высокие награды не соответствующим целям образом.

Определение 1.6. Диаграмма причинного влияния (Causal Influence Diagram). Графическое представление зависимости между переменными, действиями, наблюдениями и функциями вознаграждения, помогающее выявить потенциальные уязвимости к вмешательству в награду.

Определение 1.7. Обучение с подкреплением на основе человеческой обратной связи (RLHF). Метод, при котором модель политики обучается итеративно взаимодействуя с моделью вознаграждения, обученной на человеческих предпочтениях. Цель RLHF – согласовать поведение модели с человеческими ценностями и ожиданиями.

Определение 1.8. Переоптимизация вознаграждения (Reward Overoptimization). Ситуация, при которой оптимизация модели приводит к росту значения функции вознаграждения прокси-модели, но при этом реальные человеческие предпочтения ухудшаются.

Определение 1.9. Информационное бутылочное горлышко (Information Bottleneck, IB). Принцип построения компактного латентного представления, сохраняющего только ту информацию, которая релевантна целевой переменной, и устраняющего избыточные или случайные детали. В InfoRM данный принцип используется для фильтрации признаков, не связанных с человеческими предпочтениями.

Определение 1.10. Прокси-модель вознаграждения (Proxy Reward Model, Proxy RM). Модель, аппроксимирующая человеческие предпочтения на основе данных парных сравнений ответов. Используется в 1.7 как функция вознаграждения, которую оптимизирует модель политики.

Определение 1.11. Эталонная модель вознаграждения (Gold Reward Model, Gold RM). Модель, наилучшим образом отражающая истинные человеческие предпочтения. В симуляционных экспериментах выступает в роли эталона, по которому оценивается качество прокси-моделей.

Определение 1.12. Индекс разделения кластеров (Cluster Separation Index, CSI). Метрика, количественно измеряющая степень отклонения точек в латентном пространстве информационного бутылочного горлышка. Резкий рост значения индекса служит индикатором появления выбросов и сигнализирует о начале переоптимизации вознаграждения.

Определение 1.13. Эволюционный алгоритм (Evolutionary Algorithm, EA). Метод оптимизации, основанный на принципах естественного отбора, при котором популяция решений со временем изменяется и отбираются особи с наилучшей приспособленностью.

Определение 1.14. Поведенческое разнообразие (Behavioural Diversity). Свойство популяции, при котором особи демонстрируют различные стратегии и формы поведения при решении задачи, что способствует устойчивости поиска и предотвращает преждевременную сходимость.

Определение 1.15. Функция приспособленности (Fitness Function). Целевая функция, оценивающая качество решения или агента на основе полученного вознаграждения от среды.

Определение 1.16. Показатель безопасности (Safety Score). Метрика, отражающая степень соответствия полученной награды корректному и безопасному поведению агента, без манипуляций с функцией награды.

Определение 1.17. Особь (Individual). Отдельный агент в популяции эволюционного алгоритма, представляющий одно из возможных решений задачи и обладающий собственной функцией приспособленности.

Определение 1.18. Специализированные поведенческие характеристики (Task-Specific Behaviour Characterizatio SPC). Набор признаков, описывающих поведение агента, разработанный с использованием экспертных знаний о конкретной среде или задаче.

Определение 1.19. Общие поведенческие характеристики (Generic Behaviour Characterizations, GBC). Универсальное описание поведения агента, не зависящее от конкретной задачи и не требующее человеческой экспертизы.

Определение 1.20. Выравнивание (alignment). Свойство модели, заключающееся в соответствии её поведения и намерений разработчика.

Определение 1.21. Сеточный мир(gridworld). Двумерная дискретная среда, в которой агент может перемещаться по клеткам.

Определение 1.22. Большая языковая модель (Large Language Model). Нейросетевая модель, обученная на больших корпусах текстов для генерации ответов на естественном языке.

Определение 1.23. Игра со спецификацией (Specification Gaming). Ситуация, когда модель выполняет действия, формально соответствующие целевой функции награды, но не решающие поставленную задачу по смыслу.

Определение 1.24. Итерация эксперта (Expert Iteration). Метод обучения с подкреплением, при котором отбираются лучшие действия по значению награды и используется обучение с учителем на этих действиях.

Определение 1.25. Оптимизация проксимальной политики (Proximal Policy Optimization (PPO)). Метод обучения с подкреплением, использующий градиентный шаг политики с ограничением отклонения новой политики от старой.

Определение 1.26. Учебная последовательность игровых сред (Curriculum of Gameable Environments). Набор (куррикулум) симулированных текстовых сред, в которых модель может либо честно решать задачи, либо «играть» со спецификацией ради большего вознаграждения.

Определение 1.27. HHH-задачи (helpful, honest, harmless). Класс задач, направленных на формирование у модели поведения, которое делает её полезной, честной и безвредной при взаимодействии с пользователем.

Определение 1.28. Выравнивание агента (Agent Alignment). Свойство системы обучения с подкреплением, заключающееся в соответствии поведения агента намерениям пользователя при взаимодействии со средой.

Определение 1.29. Сдвиг распределения (Distributional Shift). Изменение распределения состояний или наблюдений, встречающихся агенту, относительно распределения, на котором обучалась модель вознаграждения; приводит к снижению точности и устойчивости оценок.

Определение 1.30. Модельно-ориентированный агент (Model-Based Agent). Агент, использующий внутреннюю модель динамики среды и процедуры планирования для прогнозирования последствий своих действий и выбора оптимального поведения.

Определение 1.31. Модель среды (Environment Model). Отображение

$$f : S \times A \to S, \tag{12}$$

аппроксимирующее динамику переходов среды: из состояния $s \in S$ при действии $a \in A$ модель предсказывает следующее состояние $s' \in S$.

Определение 1.32. Планирование (Planning). Процедура выбора действия на основе прогнозирования будущих траекторий с использованием модели среды; применяется для поиска последовательности действий, максимизирующей ожидаемое вознаграждение.

Определение 1.33. Рекурсивное моделирование вознаграждения (Recursive Reward Modeling). Метод построения иерархии агентов, при котором агент предыдущего уровня помогает человеку оценивать результаты более сложного агента, что обеспечивает масштабирование оценки на задачах высокой сложности.

Определение 1.34. Вэйрхединг (wireheading). Частный случай вмешательства, при котором агент изменяет обратную связь, увеличивая наблюдаемую награду вне зависимости от того, достигается ли истинная цель задачи.

Определение 1.35. Встроенная обратная связь (embedded feedback). Механизм предоставления обучающих сигналов агенту, при котором значения записываются в физические объекты среды (регистры), доступные для модификации агентом; такой механизм не является защищённым каналом награды.

Определение 1.36. Регистр (register). Физический объект среды, кодирующий численное значение через свои параметры (например, положение составных блоков). Регистр может быть изменён агентом, что приводит к искажению обратной связи.

Определение 1.37. Метр (meter). Датчик, функция которого вычисляет истинное значение некоторой величины на основе состояния среды. Метры используются поставщиком обратной связи для формирования сигнала.

Определение 1.38. Поставщик обратной связи (feedback provider). Компонент среды, который реализует функцию обратной связи δ, считывая значения метров и наблюдения агента и записывая вычисленные сигналы в регистры.

Определение 1.39. Марковский процесс принятия решений с повреждаемой обратной связью (Corrupt-Feedback MDP, CFMDP). Расширение классического марковского процесса принятия решений, в котором наблюдаемая агентом обратная связь может отличаться от истинной из-за действия функции коррупции c, определяемой динамикой среды.

2 Масштабируемое согласование агента посредством моделирования вознаграждения

2.1 Ключевые идеи

Статья [1] не предлагает конкретного алгоритма, а формулирует исследовательское направление, основанное на идее *моделирования вознаграждения* (reward modeling). Ключевая мысль состоит в том,

что поведение обучаемого агента можно согласовывать с намерениями пользователя, если сначала обучать отдельную модель вознаграждения по человеческой обратной связи, а затем использовать её как целевую функцию для RL-агента.

Пользователь не задаёт награду вручную, а лишь оценивает результаты поведения агента (например, выбирает более удачные траектории). Модель вознаграждения учится воспроизводить такие оценки и служит прокси-функцией для обучения агента.

Дополнительно авторы предлагают идею *рекурсивного моделирования вознаграждения*: агент предыдущего уровня помогает пользователю оценивать результаты агента следующего уровня, упрощая процесс оценки в сложных задачах. В статье это представлено как концептуальная схема (рис. 1), а не как реализованный метод.

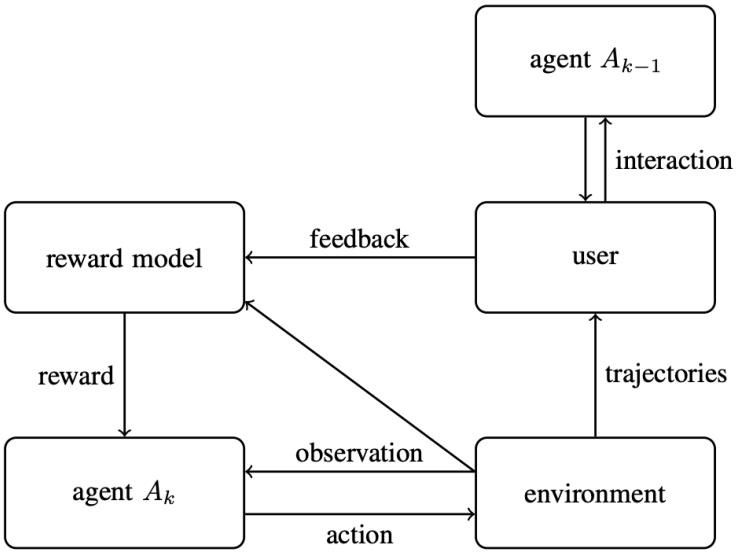


Рис. 1: Концептуальная схема рекурсивного моделирования вознаграждения. Агент A_{k-1} помогает пользователю оценить результаты агента A_k.

2.2 Описание метода

Авторы не вводят формальных определений, формул или точного алгоритма. Метод описывается лишь концептуально и включает следующие шаги:

- агент взаимодействует со средой и порождает траектории поведения;
- пользователь оценивает результаты (например, указывает предпочтения);
- модель вознаграждения обучается воспроизводить эти оценки;
- агент обновляет свою политику, ориентируясь на предсказания модели вознаграждения;
- цикл повторяется, постепенно улучшая и модель вознаграждения, и поведение агента.

Отдельно подчеркивается необходимость *онлайн-обучения*: модель вознаграждения должна обновляться параллельно с обучением агента, чтобы избежать ошибок из-за сдвига распределения.

2.3 Алгоритм

Алгоритм использует итеративную подстройку модели вознаграждения под меняющееся распределение состояний и корректирует ошибки, связанные со сдвигом распределения. Общая процедура моделирования вознаграждения может быть описана последовательностью:

1. Инициализировать модель вознаграждения R_θ и политику агента π.
2. Собрать набор траекторий $\{\tau_k\}$, сгенерированных текущей политикой.
3. Получить предпочтения пользователя над парами траекторий.
4. Обновить параметры модели вознаграждения путём минимизации функции потерь.
5. Обновить политику агента, максимизируя ожидаемое вознаграждение модели R_θ.
6. Повторять шаги 2-5, обеспечивая онлайн-обновление и адекватность оценок.

2.4 Наборы данных

В статье не используется конкретный набор данных, но сама процедура моделирования вознаграждения порождает собственный набор данных, состоящий из двух типов информации:

- Траектории поведения агента, собранные в процессе его взаимодействия со средой. Эти траектории включают наблюдения, действия и промежуточные результаты эпизодов.
- Человеческие предпочтения, полученные путём сравнения пар траекторий. Каждая аннотация задаёт бинарное предпочтение и служит обучающим сигналом для модели вознаграждения.

Подход к моделированию вознаграждения предполагает онлайн-сбор данных: по мере того как политика агента изменяется, изменяется и распределение траекторий. В связанных работах подобные схемы демонстрировались, например, на игровых средах Atari, которые используются как наглядный пример сложных задач с богатой динамикой.

2.5 Метрики

В статье не описывается формальные метрики, но обсуждаются желательные свойства:

- *Согласованность модели вознаграждения.* Оценивается совпадение между предсказаниями модели и реальными предпочтениями пользователя. В связанных работах это обычно выражается через корреляцию предсказанного и истинного вознаграждения на наборе удержанных траекторий или через точность восстановления предпочтений.
- *Производительность агента.* Измеряется итоговое суммарное вознаграждение, которое агент получает в среде, оптимизируя модель вознаграждения. Этот показатель отражает, насколько хорошо агент научился соответствовать предпочтениям пользователя, когда действует автономно.
- *Устойчивость к сдвигу распределения.* Проверяется способность модели корректно оценивать траектории, которые значительно отличаются от обучающих. Это характерно для случаев, когда политика агента улучшается и начинает посещать новые состояния.
- *Надёжность при планировании.* В задачах с моделью переходов дополнительно оценивается способность агента избегать нежелательных состояний и использовать предсказания модели среды для принятия более безопасных решений.

2.6 Модели

Структура метода включает несколько ключевых компонентов, которые взаимодействуют в процессе обучения (см. Рис 1).

- *Модель вознаграждения* R_θ. Представляет собой параметрическую функцию, обучаемую по предпочтениям пользователя. Она получает на вход траектории поведения, собранные в среде, и выдаёт скалярную оценку, которая должна согласовываться с человеческими предпочтениями.
- *Агент* A_k. Это обучаемая политика, которая взаимодействует со средой и использует предсказания модели вознаграждения для оптимизации поведения. Агент генерирует новые траектории, которые включаются в обучающий набор.
- *Вспомогательный агент* A_{k-1}. Используется в схеме рекурсивного моделирования вознаграждения. Он упрощает процесс оценки поведения агента A_k, помогая пользователю при сравнении сложных траекторий.
- *Модель переходов среды* (при наличии). Применяется в вариантах метода, где требуется планирование. Предоставляет приближённое предсказание будущих состояний по текущему состоянию и действию, что позволяет агенту оценивать потенциальные траектории без непосредственного запуска в среде.

В совокупности эти модели формируют цикл взаимодействия, в котором пользователь задаёт предпочтения, модель вознаграждения их интерпретирует, а агент адаптирует своё поведение, исходя из этих оценок.

3 REALab: встроенная перспектива на вмешательство

3.1 Ключевые идеи

Основная идея статьи [2] заключается в моделировании вмешательства в задачах обучения с подкреплением с помощью платформы REALab, которая обеспечивает *встроенную* обратную связь посредством физических регистров. В отличие от стандартных симуляторов, REALab не использует защищённый канал награды: вся обратная связь хранится в объектах среды, которые могут быть изменены агентом.

Платформа служит:

- инструментом для формального моделирования небезопасных механизмов обратной связи;
- тестовой средой для проверки устойчивости алгоритмов к вмешательству;
- операционализацией формализма CFMDP в реальной симуляции.

3.2 Математическое описание метода

Математическая структура задачи задаётся через марковский процесс принятия решений с искажённой обратной связью. Взаимодействие между агентом и средой происходит следующим образом:

$$\begin{aligned} A_t &\in A, \\ K_t &\in K, \\ D_{t+1} &= \delta(S_t, K_t), \\ \tilde{D}_{t+1} &= c(S_{t+1}, K_t, D_{t+1}), \\ S_{t+1} &\sim f(S_t, A_t), \end{aligned} \tag{13}$$

где δ – функция обратной связи, определяемая разработчиком агента, а функция c моделируется физикой симуляции.

Истинный возврат определяется как:

$$G = \sum_{t=0}^{T} \gamma^t r(S_t, A_t), \tag{14}$$

и не наблюдается агентом.

3.3 Алгоритм

REALab не задаёт фиксированный алгоритм обучения: вместо этого платформа определяет структуру взаимодействия между агентом и встроенными механизмами обратной связи. Алгоритм формируется разработчиком агента, который выбирает, каким образом использовать влияющие компоненты среды, и включает следующие шаги:

1. *Конфигурирование компонентов обратной связи.* Разработчик агента выбирает типы регистров, их расположение и необходимые метры. Эти компоненты определяют канал обратной связи, который физически присутствует в среде и подвержен вмешательству.

2. *Определение функции обратной связи δ.* Поставщик обратной связи получает наблюдения среды и (при необходимости) значения метров, после чего записывает вычисленное значение в выбранные регистры. Эта функция определяет, какие сигналы будут доступны агенту для обучения.

3. *Выбор алгоритма обучения.* Разработчик выбирает способ использования сигналов, поступающих через регистры: обучение по мгновенной награде, поведенческое клонирование, обучение по советам по ценности и т. д. Платформа не ограничивает выбор метода: она лишь предоставляет механизм доставки обучающих сигналов.

4. *Взаимодействие в ходе эпизода.* На каждом шаге агент получает наблюдение, формирует запрос K_t к поставщику обратной связи, выполняет действие A_t, после чего считывает значения из регистров. Записанное значение может отличаться от прочитанного вследствие физической динамики среды, что позволяет исследовать возникновение вмешательства.

Структура ролей проектировщика среды и проектировщика агента, а также их взаимодействие с симуляцией, показаны на Рисунке 2.

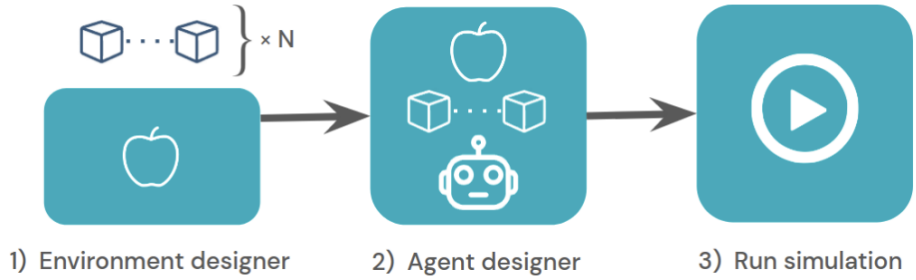


Рис. 2: Роли проектировщика среды и проектировщика агента в REALab. Проектировщик среды определяет задачу, динамику и доступные компоненты; проектировщик агента конструирует механизм обратной связи и алгоритм обучения; симулятор запускает обучение агента, который взаимодействует с компонентами среды и получает наблюдаемую, потенциально повреждённую обратную связь.

3.4 Наборы данных

В платформе REALab отсутствуют заранее подготовленные датасеты: обучение и оценка происходят непосредственно в трёхмерной симуляции. Такой формат позволяет изучать влияние действий агента на механизм обратной связи, поскольку все данные формируются динамически в процессе взаимодействия со средой. Источниками данных в REALab выступают:

- трёхмерные задачи на игровом движке Unity [3];
- задания, аналогичные средам DMLab-30 [4], например *сбор яблок* или *открытие двери*;
- компоненты среды (регистры, метры, поставщики обратной связи), которые создают обучающие сигналы во время взаимодействия агента с миром.

На Рисунке 3 приведён пример сцены в одной из задач: объект, предоставляющий награду, и *двухблочный регистр*, значение которого кодируется относительным положением блоков.

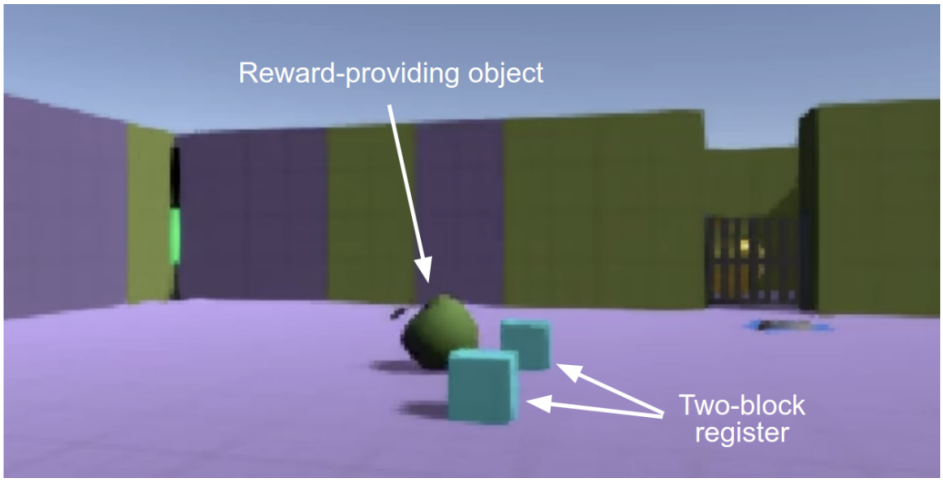


Рис. 3: Пример сцены в REALab: объект, обеспечивающий награду, и двухблочный регистр, хранящий значение обратной связи. Изменение положения блоков приводит к изменению закодированного значения, что моделирует вмешательство в механизм обратной связи.

3.5 Метрики

Для оценки поведения агента используются метрики, которые отражают два ключевых аспекта: соответствие поведения агента истинным задачам среды и наличие или отсутствие стимулов к вмешательству.

- *Истинный возврат* – основная метрика качества решения задачи. Она измеряет, насколько эффективно агент выполняет задание в соответствии с истинной функцией вознаграждения среды (которую он никогда напрямую не наблюдает). Истинный возврат определяется как сумма дисконтированных истинных наград:

$$G = \sum_{t=0}^{T} \gamma^t r(S_t, A_t). \tag{15}$$

  Высокое значение G означает, что поведение агента действительно полезно в заданном мире, а не только по наблюдаемой обратной связи.

- *Коррупция регистра* – метрика, отражающая степень вмешательства агента в каналы обратной связи. В REALab запись значения обратной связи происходит через физические регистры, которые агент может непреднамеренно или намеренно изменять. Коррупция измеряется как абсолютная разница между значением, записанным поставщиком обратной связи, и тем значением, которое затем считывает агент:

$$C = \left| D^{\text{write}} - D^{\text{read}} \right|, \tag{16}$$

где D^{write} – значение, которое поставщик обратной связи отправил в регистр, а D^{read} – значение, которое агент прочитал после физической эволюции среды.

Значение $C > 0$ указывает на то, что агент изменил регистр либо напрямую, либо косвенно.

- *Сравнение агентов по двумерному показателю* – метрика, позволяющая одновременно учитывать полезность поведения и уровень вмешательства. Для каждого агента вычисляется пара значений

$$(\text{истинный возврат},\ \text{уровень коррупции}), \tag{17}$$

что позволяет сравнивать различные архитектуры не только по успешности выполнения задания, но и по тому, насколько они склонны к вэйрхедингу или другим формам вмешательства.

3.6 Модели

REALab позволяет исследовать различные механизмы обучения, отличающиеся тем, как агент получает обратную связь через физические, подверженные вмешательству регистры. Ниже приведены три класса моделей, используемых в статье.

- *Агент с мгновенной наградой* [5]. Поставщик обратной связи считывает текущее изменение счёта через метр и записывает его в регистр. Агент воспринимает записанное значение как награду. Поскольку регистр является физическим объектом, изменение его положения или столкновения с ним приводят к искажению наблюдаемой награды.

- *Агент имитационного обучения* [6]. Поставщик обратной связи вычисляет действие демонстратора по текущему наблюдению и записывает его в регистр. Агент обучается повторять эти действия. Такая модель позволяет изучить, может ли агент стремиться менять регистр для упрощения демонстраций.

- *Агент, использующий советы по ценности* [7, 8]. Поставщик обратной связи вычисляет значение $Q(o, a)$ для наблюдения и выбранного действия, после чего записывает его в регистр. Агент стремится максимизировать наблюдаемое значение совета, что создаёт сильные стимулы к вмешательству в регистр, поскольку изменение его положения напрямую влияет на получаемую оценку.

Поведение агентов, использующих советы по ценности, иллюстрируется на Рисунке 4: когда агент оказывается рядом с регистром, он может переключиться с выполнения задачи на изменение положения регистра, повышая наблюдаемую полезность.

Каждая модель определяется выбором поставщика обратной связи:

- приращение счёта;
- действие демонстратора;
- значение $Q(o, a)$.

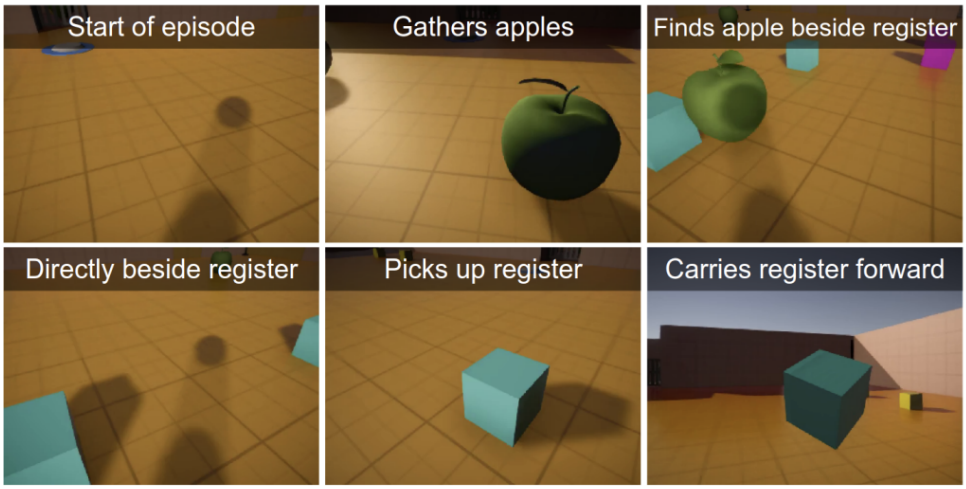


Рис. 4: Поведение агента, использующего советы по ценности: при возможности агент начинает изменять положение регистра, чтобы повысить наблюдаемое значение обратной связи, вместо выполнения исходной задачи.

Список литературы

1. Scalable agent alignment via reward modeling: a research direction / J. Leike [и др.]. — 2018. — arXiv: 1811.07871 [cs.LG]. — URL: https://arxiv.org/abs/1811.07871.
2. REALab: An Embedded Perspective on Tampering / R. Kumar [и др.]. — 2020. — arXiv: 2011.08820 [cs.LG]. — URL: https://arxiv.org/abs/2011.08820.
3. *Unity Technologies*. Unity Real-Time Development Platform. — 2018. — https://unity.com/.
4. DeepMind Lab / C. Beattie [и др.] // arXiv preprint arXiv:1612.03801. — 2016. — URL: https://arxiv.org/abs/1612.03801.
5. *Sutton R. S.*, *Barto A. G.* Reinforcement Learning: An Introduction. — MIT Press, 1998. — ISBN 9780262193986.
6. *Ross S.*, *Gordon G. J.*, *Bagnell D.* A Reduction of Imitation Learning and Structured Prediction to No-Regret Online Learning // Proceedings of the 14th International Conference on Artificial Intelligence and Statistics (AISTATS). — 2011.
7. *Knox W. B.*, *Stone P.* TAMER: Training an Agent Manually via Evaluative Reinforcement // Proceedings of the 7th International Conference on Autonomous Agents and Multiagent Systems (AAMAS Workshop). — 2008.
8. Q-Advice: A Policy-Shaping Technique for Reinforcement Learning / M. Daswani [и др.] // IEEE Transactions on Games. — 2014. — Т. 6, № 4. — С. 343—353. — DOI: 10.1109/TCIAIG.2014.2345154.