1 Основные термины и понятния

Определение 1.1. Агент –это система, которая взаимодействует со средой, воспринимает её состояние и выбирает действия с целью достижения определённой цели или максимизации функции полезности. Формально, на каждом шаге времени t агент наблюдает состояние среды S_t и выбирает действие A_t в соответствии со своей *политикой* – вероятностным распределением действий:

$$\pi(A_t \mid S_t) = P(A_t = a \mid S_t = s), \tag{1}$$

где π – стратегия (policy) агента.

Эволюция взаимодействия агента со средой описывается последовательностью:

$$S_1, A_1, R_1, S_2, A_2, R_2, \ldots, S_m, \tag{2}$$

где R_t – получаемое агентом вознаграждение на шаге t.

Цель агента – максимизация *ожидаемого суммарного вознаграждения* за эпизод:

$$J(\pi) = \mathbb{E}_{\pi,T}\left[\sum_{t=1}^{m} \gamma^{t-1} R_t\right], \tag{3}$$

где $\gamma \in [0, 1]$ – коэффициент дисконтирования, определяющий вклад будущих наград.

Для оценки качества состояния и действий агент может использовать *функции ценности*:

$$V^{\pi}(s) = \mathbb{E}_{\pi,T}\left[\sum_{t=1}^{m} \gamma^{t-1} R_t \mid S_1 = s\right], \tag{4}$$

$$Q^{\pi}(s, a) = \mathbb{E}_{\pi,T}\left[\sum_{t=1}^{m} \gamma^{t-1} R_t \mid S_1 = s, A_1 = a\right]. \tag{5}$$

Оптимальная политика π^* выбирается как:

$$\pi^*(a \mid s) = \arg\max_a Q^{\pi^*}(s, a). \tag{6}$$

Определение 1.2. Марковский процесс принятия решений (Markov Decision Process). Описывается пятёркой

$$\mathcal{M} = \langle \mathcal{S}, \mathcal{A}, T, R, \gamma \rangle, \tag{7}$$

где

$$\begin{aligned}
&\mathcal{S} \text{ – множество возможных состояний среды,} \\
&\mathcal{A} \text{ – множество допустимых действий,} \\
&T(S_{t+1} \mid S_t, A_t) \text{ – функция переходов (динамика среды),} \\
&R(S_t, A_t) \text{ – функция вознаграждения,} \\
&\gamma \text{ – коэффициент дисконтирования.}
\end{aligned} \tag{8}$$

Динамика среды определяется распределением:

$$P(S_{t+1} = s' \mid S_t = s, A_t = a) = T(s' \mid s, a). \tag{9}$$

Цель агента в MDP – найти стратегию π, максимизирующую ожидаемую дисконтированную сумму вознаграждений:

$$\pi^* = \arg\max_{\pi} \mathbb{E}_{T,\pi}\left[\sum_{t=1}^{m} \gamma^{t-1} R(S_t, A_t)\right]. \tag{10}$$

Модель MDP основывается на предположениях:

1. время дискретно;
2. следующее состояние зависит только от текущего состояния и действия (свойство Маркова); (11)
3. функция переходов стационарна во времени.

Эти условия задают формальную основу для построения и анализа систем обучения с подкреплением.

Определение 1.3. Обучение с подкреплением (Reinforcement Learning). Парадигма машинного обучения, в которой агент взаимодействует с окружающей средой, выполняя действия и получая награды, стремясь максимизировать суммарное вознаграждение со временем.

Определение 1.4. Функция вознаграждения (Reward Function). Правило или алгоритм, присваивающее числовую награду агенту в зависимости от состояния среды и действия. В статье обозначается как Θ^R – параметр определяющий поведение функции вознаграждения.

Определение 1.5. Вмешательство в награду (Reward Tampering). Ситуация, когда агент учится вмешиваться в механизм получения награды, чтобы получать более высокие награды не соответствующим целям образом.

Определение 1.6. Диаграмма причинного влияния (Causal Influence Diagram). Графическое представление зависимости между переменными, действиями, наблюдениями и функциями вознаграждения, помогающее выявить потенциальные уязвимости к вмешательству в награду.

Определение 1.7. Обучение с подкреплением на основе человеческой обратной связи (RLHF). Метод, при котором модель политики обучается итеративно взаимодействуя с моделью вознаграждения, обученной на человеческих предпочтениях. Цель RLHF – согласовать поведение модели с человеческими ценностями и ожиданиями.

Определение 1.8. Переоптимизация вознаграждения (Reward Overoptimization). Ситуация, при которой оптимизация модели приводит к росту значения функции вознаграждения прокси-модели, но при этом реальные человеческие предпочтения ухудшаются.

Определение 1.9. Информационное бутылочное горлышко (Information Bottleneck, IB). Принцип построения компактного латентного представления, сохраняющего только ту информацию, которая релевантна целевой переменной, и устраняющего избыточные или случайные детали. В InfoRM данный принцип используется для фильтрации признаков, не связанных с человеческими предпочтениями.

Определение 1.10. Прокси-модель вознаграждения (Proxy Reward Model, Proxy RM). Модель, аппроксимирующая человеческие предпочтения на основе данных парных сравнений ответов. Используется в 1.7 как функция вознаграждения, которую оптимизирует модель политики.

Определение 1.11. Эталонная модель вознаграждения (Gold Reward Model, Gold RM). Модель, наилучшим образом отражающая истинные человеческие предпочтения. В симуляционных экспериментах выступает в роли эталона, по которому оценивается качество прокси-моделей.

Определение 1.12. Индекс разделения кластеров (Cluster Separation Index, CSI). Метрика, количественно измеряющая степень отклонения точек в латентном пространстве информационного бутылочного горлышка. Резкий рост значения индекса служит индикатором появления выбросов и сигнализирует о начале переоптимизации вознаграждения.

Определение 1.13. Эволюционный алгоритм (Evolutionary Algorithm, EA). Метод оптимизации, основанный на принципах естественного отбора, при котором популяция решений со временем изменяется и отбираются особи с наилучшей приспособленностью.

Определение 1.14. Поведенческое разнообразие (Behavioural Diversity). Свойство популяции, при котором особи демонстрируют различные стратегии и формы поведения при решении задачи, что способствует устойчивости поиска и предотвращает преждевременную сходимость.

Определение 1.15. Функция приспособленности (Fitness Function). Целевая функция, оценивающая качество решения или агента на основе полученного вознаграждения от среды.

Определение 1.16. Показатель безопасности (Safety Score). Метрика, отражающая степень соответствия полученной награды корректному и безопасному поведению агента, без манипуляций с функцией награды.

Определение 1.17. Особь (Individual). Отдельный агент в популяции эволюционного алгоритма, представляющий одно из возможных решений задачи и обладающий собственной функцией приспособленности.

Определение 1.18. Специализированные поведенческие характеристики (Task-Specific Behaviour Characterizatio SPC). Набор признаков, описывающих поведение агента, разработанный с использованием экспертных знаний о конкретной среде или задаче.

Определение 1.19. Общие поведенческие характеристики (Generic Behaviour Characterizations, GBC). Универсальное описание поведения агента, не зависящее от конкретной задачи и не требующее человеческой экспертизы.

Определение 1.20. Выравнивание (alignment). Свойство модели, заключающееся в соответствии её поведения и намерений разработчика.

Определение 1.21. Сеточный мир(gridworld). Двумерная дискретная среда, в которой агент может перемещаться по клеткам.

Определение 1.22. Большая языковая модель (Large Language Model). Нейросетевая модель, обученная на больших корпусах текстов для генерации ответов на естественном языке.

Определение 1.23. Игра со спецификацией (Specification Gaming). Ситуация, когда модель выполняет действия, формально соответствующие целевой функции награды, но не решающие поставленную задачу по смыслу.

Определение 1.24. Итерация эксперта (Expert Iteration). Метод обучения с подкреплением, при котором отбираются лучшие действия по значению награды и используется обучение с учителем на этих действиях.

Определение 1.25. Оптимизация проксимальной политики (Proximal Policy Optimization (PPO)). Метод обучения с подкреплением, использующий градиентный шаг политики с ограничением отклонения новой политики от старой.

Определение 1.26. Учебная последовательность игровых сред (Curriculum of Gameable Environments). Набор (куррикулум) симулированных текстовых сред, в которых модель может либо честно решать задачи, либо «играть» со спецификацией ради большего вознаграждения.

Определение 1.27. HHH-задачи (helpful, honest, harmless). Класс задач, направленных на формирование у модели поведения, которое делает её полезной, честной и безвредной при взаимодействии с пользователем.

Определение 1.28. Выравнивание агента (Agent Alignment). Свойство системы обучения с подкреплением, заключающееся в соответствии поведения агента намерениям пользователя при взаимодействии со средой.

Определение 1.29. Сдвиг распределения (Distributional Shift). Изменение распределения состояний или наблюдений, встречающихся агенту, относительно распределения, на котором обучалась модель вознаграждения; приводит к снижению точности и устойчивости оценок.

Определение 1.30. Модельно-ориентированный агент (Model-Based Agent). Агент, использующий внутреннюю модель динамики среды и процедуры планирования для прогнозирования последствий своих действий и выбора оптимального поведения.

Определение 1.31. Модель среды (Environment Model). Отображение

$$f : S \times A \to S, \tag{12}$$

аппроксимирующее динамику переходов среды: из состояния $s \in S$ при действии $a \in A$ модель предсказывает следующее состояние $s' \in S$.

Определение 1.32. Планирование (Planning). Процедура выбора действия на основе прогнозирования будущих траекторий с использованием модели среды; применяется для поиска последовательности действий, максимизирующей ожидаемое вознаграждение.

Определение 1.33. Рекурсивное моделирование вознаграждения (Recursive Reward Modeling). Метод построения иерархии агентов, при котором агент предыдущего уровня помогает человеку оценивать результаты более сложного агента, что обеспечивает масштабирование оценки на задачах высокой сложности.

2 Масштабируемое согласование агента посредством моделирования вознаграждения

2.1 Ключевые идеи

Основная идея статьи [1] заключается в том, что согласование поведения агента можно эффективно масштабировать с помощью *моделирования вознаграждения*. Этот подход строится на разделении процесса обучения на два этапа. Сначала пользователь сравнивает траектории поведения агента, формируя предпочтения, на основе которых обучается модель вознаграждения. Затем агент использует эту модель как целевую функцию, стараясь максимизировать предсказываемое ей вознаграждение, что позволяет ему постепенно приближаться к намерениям пользователя.

Отдельное внимание в статье уделяется идее *рекурсивного моделирования вознаграждения*. В такой схеме пользователю помогает более простой агент предыдущего уровня, облегчая процесс оценки поведения текущего агента. Это позволяет применять метод на задачах, в которых пользователю сложно самостоятельно оценивать результаты взаимодействия.

Логика взаимодействия всех компонентов метода представлена на рисунке 1, где показано, как пользователь, модель вознаграждения, агенты разных уровней и среда взаимодействуют.

2.2 Математическое описание метода

Модель вознаграждения обучается на основе предпочтений пользователя, который сравнивает пары траекторий и выбирает более предпочтительную. Пусть вероятность того, что пользователь предпочитает τ_i траектории τ_j, задаётся выражением

$$P(\tau_i \succ \tau_j) = \frac{\exp\left(R_\theta(\tau_i)\right)}{\exp\left(R_\theta(\tau_i)\right) + \exp\left(R_\theta(\tau_j)\right)}. \tag{13}$$

Тогда функция потерь, минимизация которой приводит к обучению модели вознаграждения R_θ, имеет вид

$$\mathcal{L}(\theta) = -\sum_{(\tau_i, \tau_j)} \log P(\tau_i \succ \tau_j). \tag{14}$$

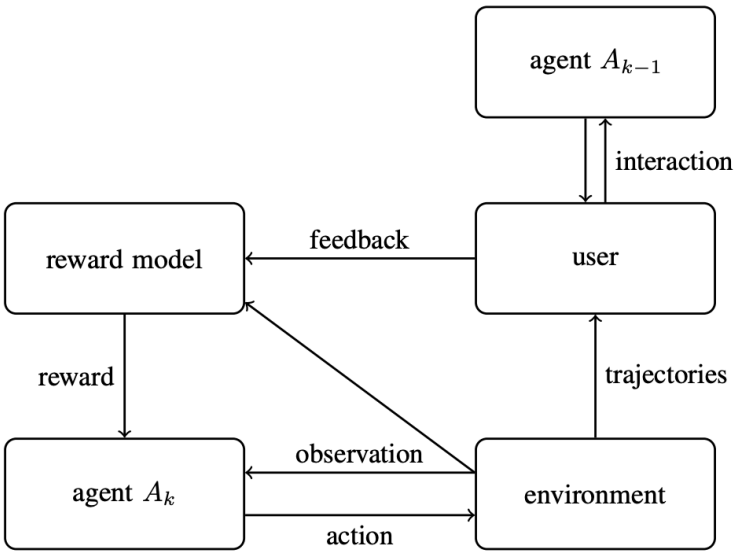


Рис. 1: Схема рекурсивного моделирования вознаграждения: агент A_{k-1} помогает пользователю оценивать поведение агента A_k, передавая информацию модели вознаграждения, которая формирует сигнал вознаграждения для агента.

Оптимизация поведения агента затем формулируется как задача максимизации ожидаемого суммарного вознаграждения модели:

$$\pi^* = \arg\max_{\pi} \mathbb{E}_{\pi} \left[\sum_{t=1}^{T} r_{\theta}(s_t, a_t) \right]. \tag{15}$$

Если используется алгоритм на основе модели среды, агент может прогнозировать будущие состояния с помощью модели переходов

$$\hat{s}_{t+1} = f(s_t, a_t), \tag{16}$$

и планировать последовательность действий, максимизирующих ожидаемое вознаграждение.

2.3 Алгоритм

Общая процедура моделирования вознаграждения может быть описана следующей последовательностью:

1. Инициализировать модель вознаграждения R_θ и политику агента π.
2. Собрать набор траекторий $\{\tau_k\}$, сгенерированных текущей политикой.
3. Получить предпочтения пользователя над парами траекторий.
4. Обновить параметры модели вознаграждения путём минимизации функции потерь.
5. Обновить политику агента, максимизируя ожидаемое вознаграждение модели R_θ.
6. Повторять шаги 2-5, обеспечивая онлайн-обновление и адекватность оценок.

Эта схема использует итеративную подстройку модели вознаграждения под меняющееся распределение состояний и корректирует ошибки, связанные со сдвигом распределения.

2.4 Наборы данных

В статье не используется конкретный набор данных, но сама процедура моделирования вознаграждения порождает собственный набор данных, состоящий из двух типов информации:

- Траектории поведения агента, собранные в процессе его взаимодействия со средой. Эти траектории включают наблюдения, действия и промежуточные результаты эпизодов.
- Человеческие предпочтения, полученные путём сравнения пар траекторий. Каждая аннотация задаёт бинарное предпочтение и служит обучающим сигналом для модели вознаграждения.

Подход к моделированию вознаграждения предполагает онлайн-сбор данных: по мере того как политика агента изменяется, изменяется и распределение траекторий. В связанных работах подобные схемы демонстрировались, например, на игровых средах Atari, которые используются как наглядный пример сложных задач с богатой динамикой.

2.5 Метрики

- *Согласованность модели вознаграждения.* Оценивается совпадение между предсказаниями модели и реальными предпочтениями пользователя. В связанных работах это обычно выражается через корреляцию предсказанного и истинного вознаграждения на наборе удержанных траекторий или через точность восстановления предпочтений.
- *Производительность агента.* Измеряется итоговое суммарное вознаграждение, которое агент получает в среде, оптимизируя модель вознаграждения. Этот показатель отражает, насколько хорошо агент научился соответствовать предпочтениям пользователя, когда действует автономно.
- *Устойчивость к сдвигу распределения.* Проверяется способность модели корректно оценивать траектории, которые значительно отличаются от обучающих. Это характерно для случаев, когда политика агента улучшается и начинает посещать новые состояния.
- *Надёжность при планировании.* В задачах с моделью переходов дополнительно оценивается способность агента избегать нежелательных состояний и использовать предсказания модели среды для принятия более безопасных решений.

2.6 Модели

Структура метода включает несколько ключевых компонентов, которые взаимодействуют в процессе обучения (см. Рис 1).

- *Модель вознаграждения* R_θ. Представляет собой параметрическую функцию, обучаемую по предпочтениям пользователя. Она получает на вход траектории поведения, собранные в среде, и выдаёт скалярную оценку, которая должна согласовываться с человеческими предпочтениями.
- *Агент* A_k. Это обучаемая политика, которая взаимодействует со средой и использует предсказания модели вознаграждения для оптимизации поведения. Агент генерирует новые траектории, которые включаются в обучающий набор.
- *Вспомогательный агент* A_{k-1}. Используется в схеме рекурсивного моделирования вознаграждения. Он упрощает процесс оценки поведения агента A_k, помогая пользователю при сравнении сложных траекторий.
- *Модель переходов среды* (при наличии). Применяется в вариантах метода, где требуется планирование. Предоставляет приближённое предсказание будущих состояний по текущему состоянию и действию, что позволяет агенту оценивать потенциальные траектории без непосредственного запуска в среде.

В совокупности эти модели формируют цикл взаимодействия, в котором пользователь задаёт предпочтения, модель вознаграждения их интерпретирует, а агент адаптирует своё поведение, исходя из этих оценок.

Список литературы

1. Scalable agent alignment via reward modeling: a research direction / J. Leike [и др.]. — 2018. — arXiv: 1811.07871 [cs.LG]. — URL: https://arxiv.org/abs/1811.07871.